



مهندسی کامپیوتر

اجماع سبک برای یادگیری فدرال سریع و دقیق تحت ناهمگونی محاسباتی و شبکه‌ای

پایان نامه کارشناسی

در رشته مهندسی کامپیوتر

آرمین افضلی

استاد راهنما:

دکتر مهرداد آشتیانی

خرداد ۱۴۰۵



تأییدیه هیئت داوران جلسه دفاع از پایان نامه / رساله

نام دانشکده: مهندسی کامپیوتر

نام دانشجو: آرمین افضلی

عنوان پایان نامه: اجماع سبک برای یادگیری فدرال سریع و دقیق تحت ناهمگونی محاسباتی و شبکه‌ای

تاریخ دفاع: خرداد ۱۴۰۵

رشته: در رشته مهندسی کامپیوتر

ردیف	سمت	نام و نام خانوادگی	دانشگاه یا مؤسسه	امضا
۱	استاد راهنما	دکتر مهرداد آشتیانی	دانشگاه علم و صنعت ایران	
۳	استاد مدعو داخلی	دکتر	دانشگاه علم و صنعت ایران	

چکیده

یادگیری فدرال یکی از رویکردهای نوین در حوزه یادگیری ماشین توزیع شده است که در آن، مدل هوش مصنوعی بدون نیاز به تبادل داده‌های خام، به صورت مشترک میان چندین گره محاسباتی آموزش می‌بیند. با گسترش روزافزون محیط‌های ابری چندگانه و ضرورت پردازش داده در لبه شبکه، پیاده‌سازی یادگیری فدرال در بسترهای ناهمگون از اهمیت ویژه‌ای برخوردار شده است. در چنین محیط‌هایی، گره‌های شرکت‌کننده از توان محاسباتی متفاوت، پهنای باند ارتباطی ناهمسان و توزیع داده غیریکنواخت برخوردارند که هر یک از این عوامل می‌توانند بر سرعت همگرایی و دقت مدل نهایی تأثیر منفی بگذارند.

در این پژوهش، یک مکانیزم اجماع سبک‌وزن تحت عنوان Trust-Weighted Adaptive Consensus (TWAC) برای بهبود فرایند تجمیع در یادگیری فدرال پیشنهاد می‌شود. این مکانیزم با نگهداری امتیاز اعتماد پویا برای هر گره، به گونه‌ای عمل می‌کند که سهم گره‌های مخرب یا پراختلال در مدل نهایی کاهش یابد، بدون آنکه هزینه محاسباتی قابل توجهی به سیستم تحمیل شود. امتیاز اعتماد هر گره بر پایه دو مؤلفه به‌روزرسانی می‌شود: همسویی جهت‌ی به‌روزرسانی آن گره با میانگین متحرک نمایی به‌روزرسانی‌های تجمیع شده گذشته، و منطقی بودن بزرگی به‌روزرسانی در مقایسه با میانه بزرگی به‌روزرسانی سایر گره‌ها. این ترکیب موجب می‌شود که روش پیشنهادی نسبت به هر دو نوع حمله جهت‌معکوس‌سازی و مقیاس‌افزایی به‌طور هم‌زمان مقاوم باشد.

برای ارزیابی روش پیشنهادی، یک بستر شبیه‌سازی محیط ابر چندگانه بر اساس مجموعه داده CIFAR-10 پیاده‌سازی شده است. در این بستر، بیست گره با توان محاسباتی و ویژگی‌های شبکه‌ای متفاوت شرکت دارند و توزیع داده میان آن‌ها از روش دیریکله با پارامتر $\alpha = 0.5$ پیروی می‌کند. نتایج آزمایش‌ها نشان می‌دهد که روش TWAC در سناریوهای بدون حمله عملکردی معادل FedAvg دارد، در حالی که در حضور گره‌های مخرب تا 30%، دقت بالاتری نسبت به روش‌های پایه به دست می‌آورد. همچنین، پیچیدگی محاسباتی این روش از مرتبه $O(nd)$ است که با FedAvg برابر و از Krum به مراتب کمتر است.

کلمات کلیدی: یادگیری فدرال، محیط ابر چندگانه، ناهمگونی محاسباتی، ناهمگونی شبکه، اجماع سبک‌وزن، مقاوم‌سازی در برابر گره‌های مخرب، توزیع داده غیریکنواخت.

فهرست مطالب

۱	فصل ۱	مقدمه
۱	۱.۱	پیش زمینه
۲	۲.۱	طرح مسئله
۳	۳.۱	چالش ها و انگیزه
۳	۴.۱	نوآوری های پژوهش
۴	۵.۱	ساختار گزارش
۵	فصل ۲	مفاهیم پایه ای
۵	۱.۲	یادگیری فدرال
۵	۱.۱.۲	تعریف و اصول کلی
۶	۲.۱.۲	الگوریتم FedAvg
۶	۳.۱.۲	همگرایی یادگیری فدرال
۷	۲.۲	انواع ناهمگونی در سیستم های توزیع شده
۷	۱.۲.۲	ناهمگونی محاسباتی
۷	۲.۲.۲	ناهمگونی شبکه
۸	۳.۲.۲	ناهمگونی داده
۸	۳.۲	خطای بیزانتین و تهدیدات امنیتی
۸	۱.۳.۲	تعریف خطای بیزانتین
۹	۲.۳.۲	روش های موجود برای مقاوم سازی
۱۰	۴.۲	محیط های ابری چندگانه
۱۰	۱.۴.۲	تعریف و ویژگی ها
۱۰	۲.۴.۲	چالش های شبکه ای در محیط ابری چندگانه
۱۱	۵.۲	مفاهیم اعتماد و اجماع

۱۱	۱.۵.۲	اجماع در سیستم‌های توزیع شده
۱۱	۲.۵.۲	مفهوم اعتماد در سیستم‌های توزیع شده
۱۲	۳.۵.۲	میانگین متحرک نمایی

فصل ۳ مروری بر کارهای پیشین

۱۳	۱.۳	دیدگاه‌های دسته‌بندی کارهای پیشین
۱۳	۱.۱.۳	دسته‌بندی بر اساس نوع ناهمگونی هدف
۱۳	۲.۱.۳	دسته‌بندی بر اساس محل مداخله
۱۴	۳.۱.۳	دسته‌بندی بر اساس نیاز به اطلاعات اضافه
۱۴	۲.۳	ملاک‌های ارزیابی و مقایسه
۱۴	۳.۳	روش‌های مقاوم‌سازی در برابر گره‌های مخرب
۱۴	۱.۳.۳	Krum و Multi-Krum
۱۵	۲.۳.۳	میانگین کوتاه‌شده و میانه
۱۵	۳.۳.۳	Bulyan
۱۵	۴.۳.۳	FLTrust
۱۵	۵.۳.۳	FedBE و FedDF
۱۶	۴.۳	روش‌های مدیریت ناهمگونی
۱۶	۱.۴.۳	FedProx
۱۶	۲.۴.۳	SCAFFOLD
۱۶	۳.۴.۳	Moon
۱۶	۴.۴.۳	FedNova
۱۷	۵.۳	رویکردهای بهینه‌سازی ارتباطی
۱۷	۱.۵.۳	ارتباط ناهمزمان
۱۷	۲.۵.۳	فشرده‌سازی گرادیان
۱۷	۳.۵.۳	انتخاب هوشمند گره
۱۷	۶.۳	جمع‌بندی و مقایسه

فصل ۴ شرح روش پیشنهادی

۱۹	۱.۴	مدل سامانه و فرضیات
۱۹	۱.۱.۴	توصیف محیط
۱۹	۲.۱.۴	فرضیات مسئله
۲۰	۲.۴	تشریح روش پیشنهادی

۲۰	گام اول: انتخاب گره و ارسال مدل	۱.۲.۴
۲۰	گام دوم: آموزش محلی و دریافت به روزرسانی ها	۲.۲.۴
۲۱	گام سوم: محاسبه امتیازات اعتماد	۳.۲.۴
۲۲	گام چهارم: تجمیع وزن دار و به روزرسانی مدل	۴.۲.۴
۲۳	مکانیزم به روزرسانی امتیاز اعتماد	۳.۴
۲۳	رفتار در حضور حمله	۱.۳.۴
۲۴	انتخاب پارامترها	۲.۳.۴
۲۴	مدیریت گره های گُند	۴.۴
۲۴	تعیین زمان مهلت تطبیقی	۱.۴.۴
۲۴	کاهش تدریجی امتیاز اعتماد گره های گُند	۲.۴.۴
۲۵	تحلیل پیچیدگی	۵.۴
۲۵	پیچیدگی محاسباتی	۱.۵.۴
۲۵	مقایسه پیچیدگی	۲.۵.۴
۲۶	بحث در مورد نوآوری	۶.۴
۲۶	تفاوت با FedAvg	۱.۶.۴
۲۶	تفاوت با Krum و میانگین کوتاه شده	۲.۶.۴
۲۶	تفاوت با FLTrust	۳.۶.۴
۳۰	شبیه سازی	فصل ۵
۳۰	محیط آزمایش و تنظیمات	۱.۵
۳۰	بستر نرم افزاری	۱.۱.۵
۳۰	مجموعه داده	۲.۱.۵
۳۱	مدل شبکه عصبی	۳.۱.۵
۳۱	توزیع داده میان گره ها	۴.۱.۵
۳۱	تنظیمات یادگیری فدرال	۵.۱.۵
۳۲	شبیه سازی ناهمگونی	۶.۱.۵
۳۲	روش های مورد مقایسه	۲.۵
۳۳	معیارهای سنجش کارایی	۳.۵
۳۳	دقت آزمون نهایی و بهترین دقت	۱.۳.۵
۳۳	خطای آزمون نهایی	۲.۳.۵
۳۳	زمان اجرا	۳.۳.۵

۳۳	آزمایش‌ها و تحلیل نتایج	۴.۵
۳۴	آزمایش ۱: مقایسه پایه (بدون حمله)	۱.۴.۵
۳۴	آزمایش ۲: مقاومت در برابر حمله جهت معکوس سازی	۲.۴.۵
۳۶	آزمایش ۳: تأثیر ناهمگونی داده	۳.۴.۵
۳۷	آزمایش ۴: مقاومت در برابر گره‌های گُند	۴.۴.۵
۳۹	جمع‌بندی نتایج	۵.۵

۴۱	نتیجه‌گیری و کارهای آینده	فصل ۶
۴۱	نتیجه‌گیری	۱.۶
۴۱	خلاصه روش پیشنهادی	۱.۱.۶
۴۲	خلاصه نتایج آزمایشی	۲.۱.۶
۴۲	بحث در مورد محدودیت‌ها	۳.۱.۶
۴۳	کارهای آینده	۲.۶
۴۳	تکرار آماری و تکمیل سناریوهای حمله	۱.۲.۶
۴۳	گسترش به مجموعه داده‌های بزرگ‌تر	۲.۲.۶
۴۳	مقاوم‌سازی در برابر حملات پیچیده‌تر	۳.۲.۶
۴۳	انتخاب تطبیقی پارامترها	۴.۲.۶
۴۳	ترکیب با فشرده‌سازی ارتباطی	۵.۲.۶
۴۴	پیاده‌سازی توزیع شده واقعی	۶.۲.۶
۴۴	تعمیم به یادگیری فدرال بدون سرور مرکزی	۷.۲.۶

۴۵	مراجع
----	-------

۴۶	واژه نامه انگلیسی به فارسی
----	----------------------------

فهرست شکل‌ها

۱.۱	نمای کلی از معماری یادگیری فدرال در محیط ابر چندگانه. هر گره داده محلی خود را نگه می‌دارد و تنها به‌روزرسانی مدل را به سرور ارسال می‌کند.	
۲	خلاصه گرافیکی آزمایش پایه: روند دقت آزمون، روند خطای آزمون، دقت نهایی چهار روش، و رفتار امتیاز اعتماد $TWAC^1$ در طول دوره‌های ارتباطی.	
۱.۵	مقایسه دقت نهایی چهار روش در سه سطح حمله جهت معکوس‌سازی: بدون حمله، 20% و 30%.	
۳۵	گره مخرب	
۳۷	روند دقت آزمون چهار روش در طول دوره‌های ارتباطی تحت ناهمگونی شدید داده ($\alpha_{dir} = 0.1$).	
۳۸	روند خطای آزمون چهار روش در طول دوره‌های ارتباطی تحت سناریوی 40% گره کُند.	
۳۹		

¹Trust-Weighted Adaptive Consensus

فهرست جدول‌ها

۱۸	مقایسه روش‌های مختلف یادگیری فدرال بر اساس ملاک‌های کلیدی	۱.۳
۲۸	فهرست نمادهای استفاده‌شده در این فصل	۱.۴
۲۹	پارامترهای روش TWAC و مقادیر پیشنهادی	۲.۴
۲۹	مقایسه پیچیدگی محاسباتی روش‌های مختلف تجميع	۳.۴
۳۱	مشخصات بستر آزمایش	۱.۵
۳۲	تنظیمات پایه آزمایش‌های یادگیری فدرال	۲.۵
۳۴	نتایج آزمایش پایه (بدون حمله، $\alpha_{dir} = 0.5$)	۳.۵
۳۶	نتایج آزمایش حمله جهت معکوس‌سازی با 20% گره مخرب	۴.۵
۳۶	نتایج آزمایش حمله جهت معکوس‌سازی با 30% گره مخرب	۵.۵
۳۷	نتایج آزمایش ناهمگونی شدید داده ($\alpha_{dir} = 0.1$)	۶.۵
۳۸	نتایج آزمایش ناهمگونی ملایم داده ($\alpha_{dir} = 1.0$)	۷.۵
۳۹	نتایج آزمایش مقاومت در برابر گره‌های کُند (40% گره کُند)	۸.۵
۴۰	جمع‌بندی دقت نهایی همه آزمایش‌ها	۹.۵

A

AWS Amazon Web Services

C

CIFAR Canadian Institute For Advanced Research

CNN Convolutional Neural Network

CPU Central Processing Unit

E

EMA Exponential Moving Average

F

FedAvg Federated Averaging

FL Federated Learning

G

GCP Google Cloud Platform

GPU Graphics Processing Unit

I

IID Independent and Identically Distributed

N

Non-IID Non-Independent and Identically Distributed

S

SGD Stochastic Gradient Descent

T

TWAC Trust-Weighted Adaptive Consensus

W

WAN Wide Area Network

در این فصل، ابتدا در **بخش ۱.۱** زمینه کلی پژوهش و اهمیت یادگیری فدرال در محیط‌های ابری چندگانه بررسی می‌شود. سپس در **بخش ۲.۱**، مسئله اصلی این پژوهش تشریح می‌گردد. در **بخش ۳.۱**، چالش‌ها و انگیزه‌های انجام این کار بیان می‌شود و در **بخش ۴.۱**، نوآوری‌های این پژوهش به اختصار فهرست می‌شود. در نهایت، **بخش ۵.۱** ساختار کلی این گزارش را توضیح می‌دهد.

۱.۱ پیش‌زمینه


در دهه اخیر، آموزش مدل‌های یادگیری ماشین به یکی از محورهای اصلی توسعه فناوری اطلاعات تبدیل شده است. رویکرد سنتی در این حوزه بر پایه تمرکز داده‌ها در یک سرور مرکزی استوار بود؛ تمام داده‌های تولیدشده توسط کاربران یا سیستم‌های مختلف به یک مخزن مشترک منتقل می‌شدند و آموزش مدل بر روی همین مخزن انجام می‌گرفت. این رویکرد اگرچه از دیدگاه سادگی پیاده‌سازی جذاب به نظر می‌رسد، اما در عمل با چالش‌های جدی روبه‌رو است؛ انتقال حجم زیادی از داده در بستر شبکه هزینه‌بر است، حریم خصوصی کاربران را به خطر می‌اندازد و در بسیاری از حوزه‌ها نظیر پزشکی، مالی و نظامی با محدودیت‌های قانونی مواجه است.

یادگیری فدرال^۱ FL که نخستین بار در سال ۲۰۱۷ توسط گوگل معرفی شد، رویکردی بدیل برای آموزش توزیع‌شده ارائه می‌دهد. در این رویکرد، هر شرکت‌کننده (که از این پس «گره» نامیده می‌شود) مدل را به صورت محلی بر روی داده‌های خود آموزش می‌دهد و تنها به‌روزرسانی‌های مدل، نه داده‌های خام، را برای تجمیع به سرور مرکزی ارسال می‌کند. این ویژگی موجب می‌شود که داده‌های حساس هرگز از محیط محلی خارج نشوند.

با گسترش خدمات ابری و پیدایش محیط‌های ابری چندگانه، یادگیری فدرال کاربردهای جدیدی یافته است. در چنین محیط‌هایی، سازمان‌ها و شرکت‌های مختلف از ارائه‌دهندگان ابری گوناگون نظیر AWS^۲، GCP^۳ و Azure بهره می‌برند. هر یک از این محیط‌ها ممکن است داده‌هایی با توزیع آماری متفاوت داشته باشند و از زیرساخت شبکه‌ای با مشخصات متمایز بهره‌مند باشند. آموزش یک مدل مشترک در چنین بستری، مسائل پیچیده‌ای را پیش می‌آورد که حل آن‌ها هدف اصلی این پژوهش است.

^۱Federated Learning
^۲Amazon Web Services

^۳Google Cloud Platform



شکل ۱.۱: نمای کلی از معماری یادگیری فدرال در محیط ابر چندگانه. هر گره داده محلی خود را نگه می‌دارد و تنها به‌روزرسانی مدل را به سرور ارسال می‌کند.

۲.۱ طرح مسئله

در یک محیط ابری چندگانه با N گره شرکت‌کننده، فرض کنید هر گره i مجموعه‌ای از داده‌های محلی D_i را در اختیار دارد. هدف کلی این است که بدون تبادل داده‌های خام، یک مدل سراسری w^* بیابیم که تابع هدف زیر را کمینه کند:

$$w^* = \arg \min_w \sum_{i=1}^N \frac{|D_i|}{|D|} \mathcal{L}_i(w; D_i) \quad (۱.۱)$$

که در آن $\mathcal{L}_i$ تابع خطای محلی گره i و $|D| = \sum_{i=1}^N |D_i|$ اندازه کل داده‌ها است.

رویکرد استاندارد برای حل این مسئله، الگوریتم FedAvg^۴ است که در هر دور ارتباطی، مراحل زیر را طی می‌کند: سرور مدل سراسری را به گره‌های منتخب ارسال می‌کند، هر گره چند دوره آموزش محلی انجام می‌دهد، سپس به‌روزرسانی‌های مدل را به سرور بازمی‌گرداند و سرور این به‌روزرسانی‌ها را با میانگین وزن دار تجمیع می‌کند.

اما در محیط‌های ابری واقعی، این فرض ساده با واقعیت فاصله دارد. چند دسته مشکل اساسی وجود دارد که FedAvg استاندارد را در این بستر ناکارآمد می‌کند:

✓ **ناهمگونی محاسباتی:** گره‌های مختلف روی انواع متفاوتی از ماشین‌های مجازی یا نمونه‌های ابری اجرا می‌شوند. یک

نمونه با GPU^۵ قوی ممکن است ده‌ها برابر سریع‌تر از یک نمونه CPU-محور باشد. این تفاوت موجب می‌شود که برخی گره‌ها

^۴Federated Averaging

^۵Graphics Processing Unit

به موقع پاسخ ندهند و دور ارتباطی تأخیر داشته باشد.

✓ **ناهمگونی شبکه:** ارتباط بین نواحی مختلف یک ارائه‌دهنده ابری یا میان ارائه‌دهندگان مختلف، از نظر تأخیر و پهنای باند یکسان نیست. پیوند درون ناحیه‌ای ممکن است تأخیر کمتر از یک میلی‌ثانیه داشته باشد، در حالی که پیوند بین دو قاره می‌تواند تأخیر بیش از ۱۵۰ میلی‌ثانیه ایجاد کند.

✓ **ناهمگونی داده:** هر ناحیه ابری یا سازمان، داده‌هایی با توزیع آماری خاص خود جمع‌آوری می‌کند. این توزیع‌ها می‌توانند با یکدیگر تفاوت چشمگیری داشته باشند، که در ادبیات این حوزه از آن با عنوان توزیع Non-IID^6 یاد می‌شود.

✓ **گره‌های معیوب یا مخرب:** در یک محیط ابری چندگانه واقعی، برخی گره‌ها ممکن است دچار خرابی نرم‌افزاری شوند، خط مشی‌های اشتباه داشته باشند یا در بدترین حالت، به طور عمدی به‌روزرسانی‌های مخرب ارسال کنند.

FedAvg هیچ مکانیزمی برای مقابله با هیچ‌یک از این مشکلات ندارد و در حضور آن‌ها عملکردش به شدت افت می‌کند.

۳.۱ چالش‌ها و انگیزه

روش‌های موجود برای مقاوم‌سازی یادگیری فدرال عمدتاً یکی از دو رویکرد کلی را دنبال می‌کنند. دسته اول روش‌هایی نظیر Krum [۱] هستند که به جای تجمیع همه به‌روزرسانی‌ها، تنها گره‌هایی را که به یکدیگر نزدیک‌ترند انتخاب می‌کنند. دسته دوم روش‌هایی نظیر میانه وزن دار [۲] و میانگین کوتاه‌شده [۲] هستند که به صورت مختصه‌به‌مختصه عمل می‌کنند.

هر دو دسته با چالش‌های جدی روبه‌رو هستند. Krum پیچیدگی محاسباتی $O(n^2d)$ دارد که در محیط‌های ابری با هزینه مستقیم محاسباتی همراه است. روش‌های مبتنی بر میانه نیز اطلاعات ارزشمند گره‌های صادق را از دست می‌دهند و سرعت همگرایی را کاهش می‌دهند. از سوی دیگر، هیچ‌یک از این روش‌ها ناهمگونی داده و مشکل گره‌های کُند را به صورت یکپارچه حل نمی‌کنند.

در محیط‌های ابری واقعی، یک مشکل اضافه نیز وجود دارد: یک گره ممکن است به دلیل یک اتفاق گذرا مثل مکث کوتاه ابری یا نوسان موقت شبکه، در یک دور ارتباطی خاص عملکرد بدی داشته باشد، اما در دورهای بعدی کاملاً طبیعی رفتار کند. اگر این گره به طور دائمی کنار گذاشته شود، اطلاعات ارزشمند داده‌های محلی آن از دست می‌رود.

این ملاحظات انگیزه اصلی این پژوهش را شکل می‌دهند: طراحی یک مکانیزم اجماع که بتواند به صورت تطبیقی و با حافظه تاریخی، رفتار هر گره را ارزیابی کند و وزن آن در تجمیع را بر اساس این ارزیابی تعیین کند؛ همه اینها بدون آنکه هزینه محاسباتی قابل توجهی به سیستم اضافه شود.

۴.۱ نوآوری‌های پژوهش

نوآوری‌های اصلی این پایان‌نامه به شرح زیر است:

✓ **ارائه مکانیزم TWAC:** یک مکانیزم اجماع سبک‌وزن با پیچیدگی $O(nd)$ که از امتیازات اعتماد تاریخی برای وزن‌دهی به گره‌ها استفاده می‌کند. این روش بر پایه دو مؤلفه همسویی جهتی و منطقی بودن بزرگی طراحی شده تا در برابر حملات

⁶Non-Independent and Identically Distributed

جهت معکوس سازی، مقیاس افزایی و نویز تصادفی مقاوم باشد؛ کارایی این روش به طور تجربی در برابر حمله جهت معکوس سازی ارزیابی شده است.

- ✓ **مدل سازی یکپارچه ناهمگونی:** بستری که ناهمگونی محاسباتی، شبکه ای و داده را به طور یکپارچه در یک پیاده سازی شبیه سازی می کند و برای اولین بار امکان مقایسه منصفانه روش های مختلف را در این فضای ناهمگون فراهم می آورد.
- ✓ **مدیریت گره های گُند:** مکانیزمی برای مدیریت گره هایی که به دلیل محدودیت های شبکه ای یا محاسباتی با تأخیر پاسخ می دهند، به گونه ای که تأخیر گذرا موجب محرومیت دائمی گره از فرایند یادگیری نشود.
- ✓ **ارزیابی تجربی جامع:** مقایسه کامل روش پیشنهادی با FedAvg، میانگین کوتاه شده و Multi-Krum در شش سناریو آزمایشی متفاوت که ترکیب های مختلفی از ناهمگونی داده، حمله بیزانتین و گره های گُند را پوشش می دهند.

۵.۱ ساختار گزارش

ساختار این پایان نامه به شرح زیر سازمان دهی شده است. نخست در **فصل ۲**، تعاریف و مفاهیم پایه ای در حوزه یادگیری فدرال، پردازش توزیع شده و بسترهای ابری بیان می شود. در **فصل ۳**، کارهای پیشین در حوزه های مقاوم سازی یادگیری فدرال، مدیریت ناهمگونی و روش های اجماع مورد بررسی قرار می گیرند. در **فصل ۴**، روش پیشنهادی این پژوهش یعنی TWAC به تفصیل تشریح می شود که شامل مدل سازی ریاضی، الگوریتم پیشنهادی و تحلیل پیچیدگی است. در **فصل ۵**، بستر شبیه سازی، آزمایش های انجام شده و تحلیل نتایج ارائه می گردد و در نهایت در **فصل ۶**، نتیجه گیری و پیشنهادات برای کارهای آینده بیان می شود.

۲ مفاهیم پایه‌ای

در این فصل، مفاهیم و تعاریف پایه‌ای که در ادامه این پایان‌نامه به آن‌ها نیاز خواهیم داشت معرفی می‌شوند. نخست در [بخش ۱.۲](#)، اصول یادگیری فدرال و الگوریتم FedAvg تشریح می‌گردد. سپس در [بخش ۲.۲](#)، انواع مختلف ناهمگونی در سیستم‌های توزیع‌شده بررسی می‌شود. در [بخش ۳.۲](#)، مفهوم خطای بیزانتین و تهدیدات امنیتی در یادگیری فدرال معرفی می‌شود. در [بخش ۴.۲](#)، ویژگی‌های محیط‌های ابری چندگانه که زمینه اصلی این پژوهش هستند بیان می‌شود و در نهایت در [بخش ۵.۲](#)، مفاهیم اعتماد و اجماع در سیستم‌های توزیع‌شده مطرح می‌گردد.

۱.۲ یادگیری فدرال

۱.۱.۲ تعریف و اصول کلی

تعریف ۱.۲ یادگیری فدرال یک رویکرد یادگیری ماشین توزیع‌شده است که در آن، یک مدل سراسری به‌صورت مشارکتی میان چندین گره آموزش می‌بیند، بدون آنکه داده‌های محلی هر گره از محیط آن خارج شود.

در فرمول‌بندی کلی یادگیری فدرال، N گره داریم که هر کدام مجموعه داده محلی $\mathcal{D}_i$ دارند. هدف کمینه‌سازی تابع زیر است:

$$F(w) = \sum_{i=1}^N \frac{|\mathcal{D}_i|}{|\mathcal{D}|} F_i(w) \quad (1.2)$$

که در آن $F_i(w) = \frac{1}{|\mathcal{D}_i|} \sum_{x \in \mathcal{D}_i} \ell(w; x)$ تابع خطای محلی گره i است و $\ell(w; x)$ خطای پیش‌بینی مدل با پارامترهای w روی نمونه x است.

نکته



تفاوت اساسی یادگیری فدرال با یادگیری توزیع شده سنتی در این است که در یادگیری فدرال، توزیع داده میان گره‌ها می‌تواند کاملاً ناهمگون باشد و تعداد نمونه‌های هر گره نیز متفاوت است. در یادگیری توزیع شده سنتی، معمولاً داده به صورت مساوی بین گره‌ها تقسیم می‌شود.

۲.۱.۲ الگوریتم FedAvg

الگوریتم FedAvg که توسط McMahan و همکاران [۳] معرفی شد، پایه‌ای‌ترین روش برای حل مسئله FL است. این الگوریتم در هر دور ارتباطی t مراحل زیر را طی می‌کند:

۱. سرور زیرمجموعه‌ای از گره‌ها $S_t \subseteq [N]$ را با اندازه K انتخاب می‌کند.
۲. سرور مدل سراسری w^t را به همه گره‌های انتخاب شده ارسال می‌کند.
۳. هر گره $i \in S_t$ برای E دوره محلی، SGD^1 را روی داده‌های خود اجرا می‌کند:

$$w_i^{t+1} \leftarrow w_i^t - \eta \nabla F_i(w_i^t) \quad (2.2)$$

۴. هر گره به روزرسانی $\Delta_i^t = w_i^{t+1} - w^t$ را به سرور ارسال می‌کند.

۵. سرور با میانگین وزن دار، مدل را به روز می‌کند:

$$w^{t+1} = w^t + \sum_{i \in S_t} \frac{|\mathcal{D}_i|}{\sum_{j \in S_t} |\mathcal{D}_j|} \Delta_i^t \quad (3.2)$$

محدودیت‌های FedAvg



الگوریتم FedAvg تحت فرضیات زیر طراحی شده است که در محیط‌های ابری واقعی اغلب برقرار نیستند: (الف) همه گره‌ها صادق و قابل اعتماد هستند، (ب) داده‌ها تقریباً به صورت IID^a توزیع شده‌اند، (ج) همه گره‌ها در زمان مشابهی پاسخ می‌دهند.

^aIndependent and Identically Distributed

۳.۱.۲ همگرایی یادگیری فدرال

تحلیل همگرایی FedAvg در حالت عمومی پیچیده است. برای حالتی که تابع F μ -محدب قوی و L -لیپشیتز پیوسته است، می‌توان نشان داد که خطای همگرایی از مرتبه زیر است:

¹Stochastic Gradient Descent

$$\mathbb{E}[F(w^T)] - F(w^*) \leq \mathcal{O}\left(\frac{1}{T} + \Gamma\right) \quad (۴.۲)$$

که در آن Γ یک اصطلاح واگرایی است که به تفاوت توزیع داده‌ها میان گره‌ها بستگی دارد. در توزیع IID، $\Gamma = 0$ است، اما در توزیع Non-IID، این اصطلاح می‌تواند بزرگ باشد و همگرایی را کند یا حتی متوقف کند.

۲.۲ انواع ناهمگونی در سیستم‌های توزیع شده

۱.۲.۲ ناهمگونی محاسباتی

ناهمگونی محاسباتی به تفاوت در توان پردازشی گره‌های مختلف اشاره دارد. در یک محیط ابری، این تفاوت می‌تواند از چند برابر تا چند ده برابر باشد.

تعریف ۲.۲ سرعت محاسباتی نسبی گره i را با $s_i \in (0, 1]$ نشان می‌دهیم که در آن $s_i = 1$ بیانگر سریع‌ترین گره و $s_i \rightarrow 0$ بیانگر کندترین گره ممکن است.

اگر زمان انجام یک دوره آموزش محلی توسط سریع‌ترین گره برابر T_0 باشد، آنگاه زمان مورد نیاز گره i برای همان تعداد دوره، برابر T_0/s_i است. در یک محیط ابری واقعی، s_i می‌تواند به سختی افزار نمونه ابری (وجود GPU، تعداد هسته‌های CPU^۲، حافظه)، بار فعلی نمونه (وجود فرایندهای موازی دیگر) و کارایی کد آموزشی محلی بستگی داشته باشد.

۲.۲.۲ ناهمگونی شبکه

ناهمگونی شبکه به تفاوت در کیفیت کانال ارتباطی میان گره‌ها و سرور اشاره دارد. این ناهمگونی به سه پارامتر اصلی زیر وابسته است:

- ✓ **تأخیر (Latency):** زمانی که یک بسته داده برای رفتن از گره به سرور (یا بالعکس) طی می‌کند. در محیط‌های ابری، این مقدار از کمتر از یک میلی‌ثانیه (درون یک ناحیه) تا بیش از ۱۵۰ میلی‌ثانیه (بین دو قاره) متفاوت است.
- ✓ **پهنای باند:** سرعت انتقال داده. ارسال یک مدل با میلیون‌ها پارامتر در یک پیوند با پهنای باند کم می‌تواند چندین دقیقه طول بکشد.
- ✓ **نرخ افت بسته:** احتمال از دست رفتن یک بسته در مسیر. در محیط‌های WAN^۳، این احتمال ناچیز نیست.

^۲Central Processing Unit

^۳Wide Area Network

تعریف ۳.۲

گره گُند (گره گُند^a) به گره‌ای گفته می‌شود که به دلیل ترکیبی از محدودیت‌های محاسباتی یا شبکه‌ای، در یک دور ارتباطی معین نمی‌تواند پیش از پایان یافتن زمان مجاز، پاسخ خود را به سرور ارسال کند.

۳.۲.۲ ناهمگونی داده

ناهمگونی داده مهم‌ترین و پیچیده‌ترین نوع ناهمگونی در یادگیری فدرال است. این ناهمگونی ناشی از آن است که داده‌های موجود در گره‌های مختلف توزیع آماری یکسانی ندارند.

تعریف ۴.۲

داده‌ها را IID می‌نامیم اگر نمونه‌های موجود در هر گره از یک توزیع مشترک و مستقل از یکدیگر نمونه‌برداری شده باشند. در غیر این صورت، داده‌ها Non-IID هستند.

۱.۳.۲.۲ مدل‌سازی ناهمگونی با توزیع دیریکله

یکی از روش‌های رایج برای مدل‌سازی ناهمگونی داده، استفاده از توزیع دیریکله است. در این روش، بردار احتمال توزیع برچسب هر گره از توزیع دیریکله با پارامتر α نمونه‌برداری می‌شود:

$$p_i \sim \text{Dir}(\alpha \cdot \mathbf{1}_C) \quad (۵.۲)$$

که در آن C تعداد کلاس‌ها و $\mathbf{1}_C$ بردار یک با طول C است. پارامتر α میزان ناهمگونی را کنترل می‌کند:

- ✓ هنگامی که $\alpha \rightarrow \infty$ ، توزیع به حالت IID نزدیک می‌شود.
- ✓ هنگامی که $\alpha = 1$ ، ناهمگونی متوسطی داریم.
- ✓ هنگامی که $\alpha \rightarrow 0$ ، هر گره فقط نمونه‌های یک یا چند کلاس را دارد (ناهمگونی شدید).

۳.۲ خطای بیزانتین و تهدیدات امنیتی

۱.۳.۲ تعریف خطای بیزانتین

تعریف ۵.۲

در یک سیستم توزیع‌شده، یک گره بیزانتین (بیزانتین^a) به گره‌ای گفته می‌شود که رفتار دلخواه و غیرقابل پیش‌بینی دارد. این رفتار ممکن است شامل ارسال مقادیر تصادفی، ارسال مقادیر حساب‌شده برای آسیب‌رسانی، یا عدم پاسخ‌دهی باشد.

در زمینه یادگیری فدرال، یک گره بیزانتین می‌تواند به‌روزرسانی‌هایی ارسال کند که مدل سراسری را به سمت نادرستی سوق دهد. مهم‌ترین انواع حملات عبارتند از:

۱.۱.۳.۲ حمله نویز تصادفی

در این حمله، گره مخرب به‌روزرسانی واقعی خود را با نویز گاوسی ترکیب می‌کند:

$$\tilde{\Delta}_i = \Delta_i + \mathcal{N}(0, \sigma^2 I) \quad (۶.۲)$$

این حمله ضعیف‌ترین نوع حمله است، چون معمولاً روش‌های ساده مبتنی بر اندازه نرم می‌توانند آن را شناسایی کنند.

۲.۱.۳.۲ حمله جهت معکوس سازی

در این حمله که به آن Sign-Flip نیز گفته می‌شود، گره مخرب علامت به‌روزرسانی خود را معکوس می‌کند:

$$\tilde{\Delta}_i = -\lambda \Delta_i, \quad \lambda > 0 \quad (۷.۲)$$

این حمله خطرناک‌تر است چون به‌روزرسانی مخرب ممکن است اندازه‌ای مشابه به‌روزرسانی‌های صادق داشته باشد.

۳.۱.۳.۲ حمله مقیاس افزایی

در این حمله، گره مخرب به‌روزرسانی خود را با یک ضریب بزرگ مقیاس می‌دهد:

$$\tilde{\Delta}_i = \kappa \Delta_i, \quad \kappa \gg 1 \quad (۸.۲)$$

هدف این حمله آن است که تأثیر گره مخرب در تجميع بسیار بزرگ‌تر از گره‌های صادق باشد.

۲.۳.۲ روش‌های موجود برای مقاوم سازی

۱.۲.۳.۲ الگوریتم Krum

Krum [۱] یک الگوریتم تجميع مقاوم است که در هر دور، m گره را انتخاب می‌کند. برای هر گره i ، امتیاز Krum به صورت زیر تعریف می‌شود:

$$s_i^{Krum} = \sum_{j \in \mathcal{N}_i} \|\Delta_i - \Delta_j\|^2 \quad (۹.۲)$$

که در آن $\mathcal{N}_i$ مجموعه $n - f - 2$ نزدیک‌ترین همسایه گره i است. گره‌هایی با کمترین امتیاز انتخاب می‌شوند.

قضیه ۱.۲

اگر $n \geq 2f + 3$ باشد که در آن f تعداد گره‌های بیزانتین است، آنگاه Krum خاصیت (α, f) -بیزانتین-مقاومت را دارد.

اثبات. اثبات کامل در [۱] آمده است. ایده اصلی اثبات این است که فاصله میان به‌روزرسانی‌های گره‌های صادق محدود است، در حالی که گره‌های بیزانتین می‌توانند به‌روزرسانی‌هایی ارسال کنند که از این مجموعه فاصله زیادی دارند. بنابراین گره‌های صادق امتیاز Krum پایین‌تری خواهند داشت.

۲.۲.۳.۲ میانگین کوتاه‌شده

میانگین کوتاه‌شده [۲] یک روش تجمیع مختصه‌ای است که در هر مختصه، β درصد از بزرگ‌ترین و کوچک‌ترین مقادیر را حذف می‌کند:

$$[\text{TrimMean}(\Delta_1, \dots, \Delta_n)]_k = \frac{1}{n - 2\lfloor \beta n \rfloor} \sum_{i=\lfloor \beta n \rfloor + 1}^{n - \lfloor \beta n \rfloor} \Delta_{\sigma_k(i), k} \quad (۱۰.۲)$$

که در آن σ_k مرتب‌سازی مختصه k ام به‌روزرسانی‌هاست.

۴.۲ محیط‌های ابری چندگانه

۱.۴.۲ تعریف و ویژگی‌ها

تعریف ۶.۲ محیط ابری چندگانه (Multi-Cloud) به وضعیتی اطلاق می‌شود که در آن یک سازمان از خدمات بیش از یک ارائه‌دهنده ابری به‌صورت هم‌زمان استفاده می‌کند. این رویکرد با هدف جلوگیری از وابستگی به یک ارائه‌دهنده، بهینه‌سازی هزینه‌ها و بهره‌برداری از بهترین قابلیت‌های هر ارائه‌دهنده اتخاذ می‌شود.

در زمینه یادگیری فدرال، محیط ابری چندگانه به معنای آن است که گره‌های شرکت‌کننده در فرایند یادگیری می‌توانند در نواحی مختلف یک ارائه‌دهنده یا روی ارائه‌دهندگان مختلف مستقر باشند.

۲.۴.۲ چالش‌های شبکه‌ای در محیط ابری چندگانه

ارتباط شبکه‌ای در یک محیط ابری چندگانه چند ویژگی اساسی دارد که آن را از شبکه‌های محلی متمایز می‌کند:

- ✓ ارتباط بین دو نمونه در یک ناحیه معمولاً تأخیر بسیار کمی دارد (زیر یک میلی ثانیه)، اما ارتباط بین دو ناحیه مختلف می‌تواند تأخیر چند ده میلی ثانیه داشته باشد.
- ✓ ارتباط بین دو ارائه‌دهنده ابری مختلف از طریق اینترنت عمومی برقرار می‌شود که تأخیر بیشتری دارد و ضمانت کیفیت سرویس (QoS) کمتری ارائه می‌دهد.
- ✓ هزینه انتقال داده بین ارائه‌دهندگان ابری مختلف (خروجی) می‌تواند قابل توجه باشد.

مطالب بیشتر



در این پژوهش، گره‌های شرکت‌کننده در یادگیری فدرال معادل نمونه‌های ابری (ماشین‌های مجازی یا کانتینرها) هستند که در نواحی مختلف یک یا چند ارائه‌دهنده ابری مستقر هستند. ناهمگونی شبکه‌ای مدل‌شده در این پژوهش، بازتاب واقعیت ارتباطات درون ناحیه‌ای، بین ناحیه‌ای و بین ارائه‌دهنده‌ای در چنین محیط‌هایی است.

^aStraggler^aByzantine

۵.۲ مفاهیم اعتماد و اجماع

۱.۵.۲ اجماع در سیستم‌های توزیع‌شده

تعریف ۷.۲ مسئله اجماع در سیستم‌های توزیع‌شده این است که چگونه گره‌های مختلف می‌توانند در مورد یک مقدار یا تصمیم مشترک به توافق برسند، حتی در حضور خرابی‌ها یا رفتارهای مخرب.

در یادگیری فدرال، مسئله تجميع مدل در واقع یک نوع مسئله اجماع است: سرور باید بر اساس ورودی‌های دریافتی از گره‌های مختلف (که برخی ممکن است معیوب یا مخرب باشند) به یک مدل مشترک برسد.

۲.۵.۲ مفهوم اعتماد در سیستم‌های توزیع‌شده

تعریف ۸.۲ امتیاز اعتماد یک گره، یک کمیت عددی است که رفتار تاریخی آن گره را در یک سیستم توزیع‌شده خلاصه می‌کند. هر چه این امتیاز بالاتر باشد، گره مورد نظر در گذشته رفتار قابل اطمینان‌تری داشته و سهم بیشتری در تصمیم‌گیری مشترک دریافت می‌کند.

استفاده از امتیاز اعتماد در سیستم‌های توزیع‌شده چند مزیت اساسی دارد. نخست، یک خرابی گذرا (مانند یک بسته از دست رفته یا یک تأخیر مقطعی) موجب محرومیت دائمی گره نمی‌شود. دوم، گره‌هایی که به‌طور مستمر رفتار غیرعادی دارند به‌تدریج تأثیر کمتری در سیستم خواهند داشت. سوم، سیستم می‌تواند به تغییر رفتار گره‌ها در طول زمان واکنش نشان دهد.

۳.۵.۲ میانگین متحرک نمایی

تعریف ۹.۲

میانگین متحرک نمایی (EMA^4) یک روش برای محاسبه میانگین وزن دار دنباله‌ای از مقادیر است که در آن

مقادیر اخیر وزن بیشتری دارند:

$$\bar{x}^t = \mu \bar{x}^{t-1} + (1 - \mu)x^t \quad (۱۱.۲)$$

که در آن $\mu \in [0, 1]$ پارامتر اینرسی است. هر چه μ به یک نزدیک‌تر باشد، تغییرات آهسته‌تر است.

EMA در روش TWAC پیشنهادی به دو منظور استفاده می‌شود: نخست برای به‌روزرسانی امتیازات اعتماد گره‌ها به گونه‌ای که تغییرات ناگهانی صاف شوند، و دوم برای نگهداری یک جهت مرجع که نمایانگر میانگین وزن دار جهت به‌روزرسانی‌های تجمیع شده گذشته است.

یادآوری

مهم‌ترین مفاهیم این فصل که در ادامه مکرراً استفاده خواهند شد: (الف) فرمول تجمیع FedAvg در معادله

(۳.۲)، (ب) مدل ناهمگونی داده با توزیع دیریکله در معادله (۵.۲)، (ج) تعریف انواع حملات بیزانتین در معادلات (۶.۲) تا

(۸.۲)، و (د) تعریف EMA در معادله (۱۱.۲).

۳ مروری بر کارهای پیشین

در این فصل، به بررسی مطالعات و پژوهش‌هایی که به طور مستقیم یا غیرمستقیم با موضوع پژوهش حاضر مرتبط هستند، می‌پردازیم تا دید جامعی از آنچه تاکنون در زمینه‌های مرتبط انجام شده ارائه دهیم. ابتدا در **بخش ۱.۳**، دیدگاه‌های مختلف برای دسته‌بندی کارهای پیشین بیان می‌شود. در **بخش ۲.۳**، ملاک‌های ارزیابی و مقایسه تعریف می‌گردند. در **بخش ۳.۳**، روش‌های مقاوم‌سازی در برابر گره‌های مخرب مرور می‌شود. در **بخش ۴.۳**، روش‌های مدیریت ناهمگونی بررسی می‌گردد. در **بخش ۵.۳**، رویکردهای بهینه‌سازی ارتباطی ارائه می‌شود و در نهایت در **بخش ۶.۳**، جمع‌بندی و جدول مقایسه‌ای ارائه می‌گردد.

۱.۳ دیدگاه‌های دسته‌بندی کارهای پیشین

پژوهش‌های مرتبط با یادگیری فدرال در محیط‌های ناهمگون را می‌توان از سه دیدگاه کلی دسته‌بندی کرد:

۱.۱.۳ دسته‌بندی بر اساس نوع ناهمگونی هدف

اولین دیدگاه تقسیم‌بندی پژوهش‌ها بر اساس نوع ناهمگونی است که هر کار با آن مقابله می‌کند:

- ✓ **ناهمگونی داده:** پژوهش‌هایی که تمرکز اصلی آن‌ها بر مسئله توزیع Non-IID و واگرایی مدل‌های محلی است. نمونه‌های شاخص این دسته شامل FedProx [۴]، SCAFFOLD [۵] و Moon [۶] هستند.
- ✓ **ناهمگونی سیستمی:** پژوهش‌هایی که به تفاوت در توان محاسباتی و شبکه‌ای گره‌ها می‌پردازند. FedProx و Asyn-chronous FL [۷] از این دسته‌اند.
- ✓ **ناهمگونی بیزانتین:** پژوهش‌هایی که هدف آن‌ها مقاوم‌سازی در برابر گره‌های مخرب است. Krum [۱]، میانگین کوتاه‌شده [۲] و Bulyan [۸] از این دسته‌اند.

۲.۱.۳ دسته‌بندی بر اساس محل مداخله

دومین دیدگاه بر این اساس است که مداخله اصلی در کجای فرایند یادگیری فدرال انجام می‌شود:

- ✓ **مداخله در تجمیع:** روش‌هایی که الگوریتم تجمیع سرور را تغییر می‌دهند (مانند Krum، میانگین کوتاه‌شده).

- ✓ **مداخله در آموزش محلی:** روش‌هایی که فرایند آموزش در هر گره را تغییر می‌دهند (مانند FedProx که یک اصطلاح منظم‌ساز به تابع هدف محلی اضافه می‌کند).
- ✓ **مداخله در ارتباطات:** روش‌هایی که به بهینه‌سازی تبادل اطلاعات بین گره‌ها و سرور می‌پردازند (فشرده‌سازی گرادیان، ارتباط ناهمزمان).

۳.۱.۳ دسته‌بندی بر اساس نیاز به اطلاعات اضافه

- سومین دیدگاه بر اساس میزان اطلاعات فراسازمانی که هر روش نیاز دارد است:
- ✓ **بدون نیاز به اطلاعات جانبی:** روش‌هایی که تنها بر اساس به‌روزرسانی‌های دریافتی در هر دور تصمیم می‌گیرند.
 - ✓ **نیاز به داده‌های اعتبارسنجی:** روش‌هایی که برای ارزیابی کیفیت به‌روزرسانی‌ها به یک مجموعه داده اعتبارسنجی در سرور نیاز دارند.
 - ✓ **نیاز به تاریخچه:** روش‌هایی که رفتار گذشته گره‌ها را نگهداری می‌کنند و در تصمیم‌گیری استفاده می‌کنند.

۲.۳ ملاک‌های ارزیابی و مقایسه

برای مقایسه منصفانه روش‌های مختلف، شش ملاک کلیدی زیر را در نظر می‌گیریم:

۱. **دقت نهایی مدل:** دقت مدل سراسری روی مجموعه آزمون در پایان آموزش.
۲. **سرعت همگرایی:** تعداد دورهای ارتباطی مورد نیاز برای رسیدن به یک دقت هدف مشخص.
۳. **پیچیدگی محاسباتی:** هزینه محاسباتی الگوریتم تجمیع در سرور، بر حسب تعداد گره‌ها n و ابعاد مدل d .
۴. **مقاومت در برابر حمله:** توانایی حفظ دقت مدل در حضور گره‌های مخرب.
۵. **مقاومت در برابر ناهمگونی داده:** توانایی همگرایی در حضور توزیع Non-IID.
۶. **مدیریت گره‌های کُند:** توانایی ادامه آموزش بدون وابستگی به پاسخ همه گره‌ها.

۳.۳ روش‌های مقاوم‌سازی در برابر گره‌های مخرب

۱.۳.۳ Krum و Multi-Krum

Krum [۱] اولین روش با ضمانت نظری برای یادگیری فدرال مقاوم بود. ایده اصلی آن این است که به‌روزرسانی‌های گره‌های صادق باید به یکدیگر نزدیک باشند (از نظر فاصله اقلیدسی در فضای پارامتر). بنابراین، گره‌هایی که به‌روزرسانی‌شان با سایر گره‌ها فاصله زیادی دارد، احتمالاً مخرب هستند.

تابع امتیاز Krum برای گره i به شکل زیر است:

$$s(i) = \sum_{j \rightarrow i} \|\Delta_i - \Delta_j\|^2 \quad (۱.۳)$$

که $j \rightarrow i$ به معنای j در میان $n - f - 2$ نزدیک‌ترین همسایه i است.

این روش چند محدودیت اساسی دارد. نخست، پیچیدگی محاسباتی $O(n^2d)$ دارد که با افزایش تعداد گره‌ها یا ابعاد مدل، هزینه‌بر می‌شود. دوم، در حالت Single-Krum (انتخاب فقط یک گره) نرخ همگرایی کند است. سوم، در برابر حملاتی که جهت مشابه گره‌های صادق دارند (مثل حملات هم‌راستای ظریف) آسیب‌پذیر است.

Multi-Krum [۱] نسخه بهبودیافته است که $m > 1$ گره با کمترین امتیاز را انتخاب می‌کند. این موجب بهبود همگرایی می‌شود اما پیچیدگی محاسباتی یکسان دارد.

۲.۳.۳ میانگین کوتاه‌شده و میانه

Yin و همکاران [۲] دو روش مختصه‌ای مقاوم ارائه دادند. در میانگین کوتاه‌شده، در هر مختصه، β درصد از بزرگ‌ترین و کوچک‌ترین مقادیر حذف و میانگین مقادیر باقی‌مانده محاسبه می‌شود. پیچیدگی این روش $O(nd \log n)$ است.

در روش میانه، در هر مختصه، میانه مقادیر به‌عنوان مقدار تجمیع‌شده انتخاب می‌شود. این روش پیچیدگی $O(nd)$ دارد و از نظر مقاومت نظری قوی است، اما در عمل همگرایی کندتری نسبت به میانگین کوتاه‌شده دارد زیرا واریانس بالاتری دارد.

۳.۳.۳ Bulyan

Bulyan [۸] یک ترکیب دو مرحله‌ای است: در مرحله اول از Krum برای انتخاب زیرمجموعه‌ای از گره‌های احتمالاً صادق استفاده می‌کند، و در مرحله دوم میانگین کوتاه‌شده را روی این زیرمجموعه اعمال می‌کند. این ترکیب از نظر نظری قوی‌تر است، اما پیچیدگی محاسباتی آن نیز بالاتر است و نیاز به $n \geq 4f + 3$ دارد.

۴.۳.۳ FLTrust

FLTrust [۹] یک رویکرد متفاوت را دنبال می‌کند. سرور یک مجموعه داده کوچک و قابل اعتماد دارد و مدل خود را روی آن آموزش می‌دهد. به‌روزرسانی هر گره بر اساس شباهت کسینوسی آن با به‌روزرسانی سرور وزن‌دهی می‌شود. این روش در عمل نتایج خوبی داشته، اما نیاز به داده اعتبارسنجی در سرور دارد که در بسیاری از سناریوهای واقعی در دسترس نیست.

۵.۳.۳ FedBE و FedDF

این دو روش [۱۰، ۱۱] از تقطیر دانش (Knowledge Distillation) برای تجمیع استفاده می‌کنند. به جای میانگین مستقیم پارامترهای مدل، مدل سراسری را با استفاده از خروجی مدل‌های محلی روی یک داده کوچک در سرور آموزش می‌دهند. این رویکرد در برابر ناهمگونی داده قوی است اما نیاز به داده در سرور دارد.

۴.۳ روش‌های مدیریت ناهمگونی

FedProx ۱.۴.۳

FedProx [۴] با افزودن یک اصطلاح منظم‌ساز به تابع هدف محلی، واگرایی مدل‌های محلی از مدل سراسری را محدود می‌کند:

$$\min_w F_i(w) + \frac{\mu}{2} \|w - w^t\|^2 \quad (۲.۳)$$

پارامتر μ شدت منظم‌سازی را کنترل می‌کند. این روش همچنین امکان آموزش ناقص در گره‌های گُند را فراهم می‌کند که برای محیط‌های ناهمگون مفید است. FedProx در برابر ناهمگونی داده بهتر از FedAvg عمل می‌کند، اما مکانیزمی برای مقاوم‌سازی در برابر گره‌های مخرب ندارد.

SCAFFOLD ۲.۴.۳

SCAFFOLD [۵] ریشه واگرایی مدل‌های محلی در توزیع Non-IID را در نوسانات واریانس گرادیان می‌داند. این روش از متغیرهای کنترلی c_i و c برای اصلاح به‌روزرسانی‌های محلی استفاده می‌کند:

$$w_i \leftarrow w_i - \eta(g_i - c_i + c) \quad (۳.۳)$$

این روش همگرایی نظری قوی‌تری دارد اما دو برابر FedAvg ارتباط نیاز دارد.

Moon ۳.۴.۳

Moon [۶] از یادگیری مقایسه‌ای (Contrastive Learning) برای بهبود آموزش محلی استفاده می‌کند. ایده اصلی این است که نمایش مدل محلی باید به نمایش مدل سراسری نزدیک باشد و از نمایش مدل محلی قبلی فاصله داشته باشد.

FedNova ۴.۴.۳

FedNova [۱۲] مشکل واگرایی را از منظر نرخ تغییر مؤثر مدل مورد بررسی قرار می‌دهد. این روش به‌روزرسانی‌های گره‌ها را بر اساس تعداد واقعی مراحل SGD که هر گره انجام داده نرمال‌سازی می‌کند.

۵.۳ رویکردهای بهینه‌سازی ارتباطی

۱.۵.۳ ارتباط ناهمزمان

در یادگیری فدرال ناهمزمان [۷]، سرور منتظر پاسخ همه گره‌های انتخاب‌شده نمی‌ماند و به محض دریافت به‌روزرسانی از هر گره، مدل را به‌روز می‌کند. این رویکرد مشکل گره‌های کند را حل می‌کند، اما ممکن است به دلیل استفاده از اطلاعات قدیمی (به اصطلاح Staleness)، پایداری آموزش را تحت تأثیر قرار دهد.

۲.۵.۳ فشرده‌سازی گرادیان

یکی از راه‌های کاهش حجم ارتباطات در یادگیری فدرال، فشرده‌سازی به‌روزرسانی‌های ارسالی است. روش‌های متداول شامل کوانتیزاسیون [۱۳] و هرس (Sparsification/Pruning) [۱۴] هستند. این روش‌ها ابعاد داده ارسالی را کاهش می‌دهند اما ممکن است خطا وارد کنند.

۳.۵.۳ انتخاب هوشمند گره

برخی از پژوهش‌ها به جای انتخاب تصادفی گره‌ها در هر دور، از معیارهای هوشمندانه‌تری استفاده می‌کنند [۱۵]. معیارهایی نظیر حجم داده محلی، توان محاسباتی، یا تنوع داده‌ای می‌توانند در انتخاب گره‌های مشارکت‌کننده مؤثر باشند.

۶.۳ جمع‌بندی و مقایسه

بررسی کارهای پیشین نشان می‌دهد که هیچ روش موجودی به‌طور هم‌زمان سه چالش اصلی محیط‌های ابری چندگانه را حل نمی‌کند: مقاومت در برابر گره‌های مخرب، مدیریت ناهمگونی داده، و مدیریت گره‌های کند. به علاوه، روش‌هایی که در برابر گره‌های مخرب قوی هستند (مانند Krum) پیچیدگی محاسباتی بالایی دارند که در محیط‌های ابری با هزینه مستقیم همراه است.

روش پیشنهادی این پژوهش، TWAC، با استفاده از امتیازات اعتماد تاریخی و یک مکانیزم دو-مؤلفه‌ای سبک‌وزن، به همه این چالش‌ها به‌صورت یکپارچه پاسخ می‌دهد. جدول ۱.۳ مقایسه جامع روش‌های مختلف را نشان می‌دهد.

جدول ۱.۳ به روشنی نشان می‌دهد که روش TWAC تنها روشی است که بدون نیاز به داده اعتبارسنجی در سرور، مقاومت در برابر گره‌های مخرب، مدیریت ناهمگونی داده و مدیریت گره‌های کند را با هم ترکیب می‌کند، و این کار را با پیچیدگی محاسباتی بهینه $O(nd)$ انجام می‌دهد.

جدول ۱.۳: مقایسه روش‌های مختلف یادگیری فدرال بر اساس ملاک‌های کلیدی

روش	پیچیدگی	مقاومت بیزانتین	ناهمگونی داده	گره‌گند	داده سرور	حافظه تاریخی
FedAvg	$O(nd)$	$\times$	متوسط	$\times$	$\times$	$\times$
FedProx	$O(nd)$	$\times$	خوب	بله	$\times$	$\times$
SCAFFOLD	$O(nd)$	$\times$	خوب	$\times$	$\times$	$\times$
Krum	$O(n^2d)$	قوی	ضعیف	$\times$	$\times$	$\times$
میانگین کوتاه‌شده	$O(nd \log n)$	خوب	متوسط	$\times$	$\times$	$\times$
میانه	$O(nd)$	خوب	متوسط	$\times$	$\times$	$\times$
Bulyan	$O(n^2d)$	قوی	ضعیف	$\times$	$\times$	$\times$
FLTrust	$O(nd)$	قوی	متوسط	$\times$	بله	$\times$
FedNova	$O(nd)$	$\times$	خوب	بله	$\times$	$\times$
TWAC (این پژوهش)	$O(nd)$	قوی	خوب	بله	$\times$	بله

۴ شرح روش پیشنهادی

در این فصل، روش پیشنهادی این پژوهش یعنی TWAC به تفصیل تشریح می‌شود. ابتدا در **بخش ۱.۴**، مدل سامانه و فرضیات مسئله بیان می‌گردد. سپس در **بخش ۲.۴**، الگوریتم پیشنهادی در چهار گام اصلی شرح داده می‌شود. در **بخش ۳.۴**، مکانیزم به‌روزرسانی امتیاز اعتماد به صورت دقیق‌تر بررسی می‌گردد. در **بخش ۴.۴**، نحوه مدیریت گره‌های گند توضیح داده می‌شود. در **بخش ۵.۴**، پیچیدگی محاسباتی و مقایسه آن با روش‌های موجود ارائه می‌گردد و در نهایت در **بخش ۶.۴**، نوآوری روش پیشنهادی در مقایسه با کارهای پیشین مورد بحث قرار می‌گیرد.

۱.۴ مدل سامانه و فرضیات

۱.۱.۴ توصیف محیط

سامانه مورد بررسی شامل یک سرور مرکزی (مرکز تجمع) و N گره شرکت‌کننده است که در یک محیط ابری چندگانه مستقر هستند. هر گره $i \in [N] = \{1, 2, \dots, N\}$ دارای ویژگی‌های زیر است:

- ✓ **داده محلی:** هر گره مجموعه داده $\mathcal{D}_i$ را در اختیار دارد که از نمونه‌های (x, y) تشکیل شده است. این داده‌ها هرگز مستقیماً به اشتراک گذاشته نمی‌شوند.
- ✓ **سرعت محاسباتی:** هر گره دارای سرعت محاسباتی نسبی $s_i \in (0, 1]$ است که منعکس‌کننده توان پردازشی نمونه ابری آن است.
- ✓ **مشخصات شبکه:** هر گره از نظر تأخیر و پهنای باند ارتباطی با سرور متفاوت است.
- ✓ **رفتار:** هر گره یا صادق است (به‌روزرسانی واقعی ارسال می‌کند) یا مخرب (به‌روزرسانی دست‌کاری شده ارسال می‌کند). $f < N/2$ تعداد گره‌های مخرب است.

۲.۱.۴ فرضیات مسئله

روش پیشنهادی بر پایه فرضیات زیر طراحی شده است:

- ✓ سرور کاملاً قابل اعتماد است و آسیب‌پذیری ندارد.

- ✓ گره‌های مخرب می‌توانند هر به‌روزرسانی دلخواهی ارسال کنند، اما نمی‌توانند پیام‌های گره‌های دیگر را جعل کنند.
- ✓ کانال ارتباطی میان سرور و گره‌ها احراز هویت شده است (یعنی سرور می‌داند کدام پیام از کدام گره آمده است).
- ✓ تعداد گره‌های مخرب f کمتر از نصف تعداد گره‌های شرکت‌کننده در هر دور است: $f < K/2$.
- ✓ گره‌های صادق توزیع داده غیریکنواخت دارند، اما گرادیان‌هایشان در جهت کلی یادگیری همراستا هستند.

نکته

فرض آخر کلید طراحی مؤلفه همسویی جهتی در TWAC است. در توزیع Non-IID، گرادیان‌های گره‌های صادق ممکن است از نظر بزرگی و دقیقاً از نظر جهت متفاوت باشند، اما اگر همه گره‌ها در حال یادگیری یک مدل مشترک هستند، جهت کلی به‌روزرسانی‌هایشان باید تا حدی همراستا باشد. گره‌های مخرب با حمله جهت معکوس‌سازی این همراستایی را می‌شکنند.

^aExponential Moving Average



۲.۴ تشریح روش پیشنهادی

روش TWAC از چهار گام اصلی تشکیل شده است که در هر دور ارتباطی اجرا می‌شوند.

۱.۲.۴ گام اول: انتخاب گره و ارسال مدل

در ابتدای هر دور t ، سرور زیرمجموعه‌ای از گره‌ها S_t با اندازه K را به‌صورت تصادفی یکنواخت از میان N گره انتخاب می‌کند و مدل سراسری w^t را به آن‌ها ارسال می‌کند.

۲.۲.۴ گام دوم: آموزش محلی و دریافت به‌روزرسانی‌ها

هر گره $i \in S_t$ پس از دریافت w^t ، فرایند آموزش محلی را برای E دوره اجرا می‌کند:

$$w_i^{t,e+1} = w_i^{t,e} - \eta \nabla F_i(w_i^{t,e}; \xi_i^e) \quad (۱.۴)$$

که در آن ξ_i^e یک دسته تصادفی از داده‌های محلی گره i است. پس از اتمام آموزش محلی، گره به‌روزرسانی زیر را به سرور ارسال می‌کند:

$$\Delta_i^t = w_i^{t,E} - w^t \quad (۲.۴)$$

سرور تا یک زمان مهلت $T_{\max}$ منتظر می ماند و مجموعه گره هایی که پاسخ دادند را $R_t \subseteq S_t$ می نامد.

۳.۲.۴ گام سوم: محاسبه امتیازات اعتماد

این گام قلب روش TWAC است. برای هر گره $i \in R_t$ ، دو مؤلفه زیر محاسبه می شوند:

۱.۳.۲.۴ مؤلفه اول: همسویی جهتی

این مؤلفه، شباهت کسینوسی بین به روزرسانی گره i و جهت مرجع $\bar{\Delta}^{t-1}$ را اندازه می گیرد:

$$c_i^t = \frac{\langle \Delta_i^t, \bar{\Delta}^{t-1} \rangle}{\|\Delta_i^t\| \cdot \|\bar{\Delta}^{t-1}\| + \epsilon} \quad (۳.۴)$$

که در آن $\epsilon > 0$ یک عدد کوچک برای پایداری عددی است. این مقدار در بازه $[-1, 1]$ است. اگر c_i^t منفی باشد، یعنی گره i به روزرسانی ای در جهت مخالف مسیر یادگیری ارسال کرده که نشانه ای قوی از حمله جهت معکوس سازی است.

۱.۴ قضیه

اگر گره i یک گره مخرب با حمله جهت معکوس سازی باشد، آنگاه $c_i^t < 0$ با احتمال زیاد برقرار است.

اثبات. فرض کنید گره i به روزرسانی $\tilde{\Delta}_i^t = -\lambda \Delta_i^t$ را ارسال می کند. آنگاه:

$$c_i^t = \frac{\langle -\lambda \Delta_i^t, \bar{\Delta}^{t-1} \rangle}{\|\lambda \Delta_i^t\| \cdot \|\bar{\Delta}^{t-1}\|} = -\lambda \cdot \frac{\langle \Delta_i^t, \bar{\Delta}^{t-1} \rangle}{\|\Delta_i^t\| \cdot \|\bar{\Delta}^{t-1}\|}$$

از آنجا که $\lambda > 0$ و Δ_i^t به روزرسانی یک گره صادق است که تمایل به هم راستایی با $\bar{\Delta}^{t-1}$ دارد، حاصل منفی خواهد شد. ■

۲.۳.۲.۴ مؤلفه دوم: منطقی بودن بزرگی

این مؤلفه، بزرگی نرم به روزرسانی گره i را نسبت به میانه بزرگی به روزرسانی های همه گره های پاسخ داده شده در نظر می گیرد:

$$m_i^t = \exp \left(-\alpha \cdot \max \left(0, \frac{\|\Delta_i^t\|}{\text{median}_{j \in R_t} (\|\Delta_j^t\|)} - \beta \right) \right) \quad (۴.۴)$$

که در آن $\alpha > 0$ ضریب حساسیت و $\beta > 1$ آستانه تحمل است. این مؤلفه به گونه ای طراحی شده که:

✓ اگر نرم به روزرسانی گره i کمتر از β برابر میانه باشد، $m_i^t \approx 1$ (جریمه ای ندارد).

✓ اگر نرم به روزرسانی بسیار بزرگتر از میانه باشد، $m_i^t \rightarrow 0$ (جریمه سنگین).

استفاده از میانه به جای میانگین موجب می‌شود که این مؤلفه خود در برابر گره‌های مخرب مقاوم باشد.

لم ۱.۴. در حضور حداکثر $|R_t|/2 < f$ گره مخرب، میانه نرم به‌روزرسانی‌ها تخمین پایداری از نرم میانگین به‌روزرسانی‌های صادق است.

اثبات لم. اگر کمتر از نصف گره‌های موجود در R_t مخرب باشند، میانه مجموعه نرم‌ها همیشه در ناحیه‌ای قرار می‌گیرد که حداقل نیمی از عناصر آن متعلق به گره‌های صادق هستند. بنابراین میانه نمی‌تواند توسط گره‌های مخرب به سمت مقادیر دلخواه سوق داده شود.

□

۳.۳.۲.۴ امتیاز خام

امتیاز خام گره i در دور t از ترکیب دو مؤلفه فوق به‌دست می‌آید:

$$s_i^t = \text{ReLU}(c_i^t) \cdot m_i^t \quad (۵.۴)$$

عملگر ReLU موجب می‌شود که به‌روزرسانی‌هایی با همسویی منفی امتیاز صفر بگیرند.

۴.۳.۲.۴ به‌روزرسانی امتیاز اعتماد

امتیاز اعتماد هر گره با استفاده از EMA به‌روز می‌شود:

$$\tau_i^t = \gamma \cdot \tau_i^{t-1} + (1 - \gamma) \cdot s_i^t \quad (۶.۴)$$

که در آن $\gamma \in [0, 1)$ پارامتر اینرسی است. مقدار اولیه امتیاز اعتماد همه گره‌ها $\tau_i^0 = 1$ است.

۴.۲.۴ گام چهارم: تجمیع وزن‌دار و به‌روزرسانی مدل

با استفاده از امتیازات اعتماد، مدل سراسری به‌روز می‌شود:

$$w^{t+1} = w^t + \sum_{i \in R_t} \hat{w}_i^t \cdot \Delta_i^t \quad (۷.۴)$$

که وزن‌های نرمال شده $\hat{w}_i^t$ به شکل زیر محاسبه می‌شوند:

$$\hat{w}_i^t = \frac{\hat{\tau}_i^t \cdot n_i}{\sum_{j \in R_t} \hat{\tau}_j^t \cdot n_j} \quad (۸.۴)$$

و $\hat{\tau}_i^t = \max(\tau_i^t, \tau_{\min})$ امتیاز اعتماد با کف است. کف اعتماد $\tau_{\min} > 0$ از محرومیت دائمی گره‌ها جلوگیری می‌کند. پس از به‌روزرسانی مدل، جهت مرجع نیز با EMA به‌روز می‌شود:

$$\bar{\Delta}^t = \mu \cdot \bar{\Delta}^{t-1} + (1 - \mu) \cdot \sum_{i \in R_t} \frac{\hat{\tau}_i^t}{\sum_{j \in R_t} \hat{\tau}_j^t} \cdot \Delta_i^t \quad (۹.۴)$$

۳.۴ مکانیزم به‌روزرسانی امتیاز اعتماد

۱.۳.۴ رفتار در حضور حمله

رفتار امتیاز اعتماد در سه سناریو اصلی به شرح زیر است:

۱.۱.۳.۴ گره صادق با رفتار عادی

برای یک گره صادق که توزیع داده‌اش نسبتاً عادی است، انتظار داریم $c_i^t \approx 0.7$ تا 1 و $m_i^t \approx 1$ باشد. در نتیجه $s_i^t \approx 0.7$ تا 1 و امتیاز اعتماد به تدریج به سمت این مقدار همگرا می‌شود.

۲.۱.۳.۴ گره مخرب با حمله جهت معکوس‌سازی

برای این گره، $c_i^t < 0$ خواهد بود، بنابراین $s_i^t = 0$. با گذشت چند دور، امتیاز اعتماد گره کاهش می‌یابد:

$$\tau_i^{t+k} \approx \gamma^k \tau_i^t \quad (۱۰.۴)$$

پس از $k = \lceil \log_{\gamma}(\tau_{\min}/\tau_i^0) \rceil$ دور، امتیاز اعتماد گره به کف $\tau_{\min}$ می‌رسد.

۳.۱.۳.۴ گره با رفتار نویزی

برای گره‌ای که نویز تصادفی ارسال می‌کند، c_i^t در هر دور تصادفی است و m_i^t ممکن است کوچک باشد (اگر نویز بزرگ باشد). در نتیجه امتیاز اعتماد این گره به یک مقدار متوسط همگرا می‌شود که کمتر از گره‌های صادق است.

قضیه ۲.۴

فرض کنید در هر دور، امتیاز خام گره i به طور مستقل از توزیع P_i نمونه برداری می شود با انتظار $\mathbb{E}[s_i] = \bar{s}_i$. آنگاه امتیاز اعتماد τ_i^t با احتمال یک به $\bar{s}_i$ همگرا می شود:

$$\lim_{t \rightarrow \infty} \tau_i^t = \bar{s}_i \quad \text{a.s.} \quad (11.4)$$

اثبات. از بسط معادله (۶.۴) داریم:

$$\tau_i^t = \gamma^t \tau_i^0 + (1 - \gamma) \sum_{k=1}^t \gamma^{t-k} s_i^k$$

با گذشت $t \rightarrow \infty$ ، جمله اول به صفر میل می کند. جمله دوم طبق قانون اعداد بزرگ به $\bar{s}_i = (1 - \gamma) \cdot \frac{1}{1 - \gamma} \cdot \bar{s}_i$ همگرا می شود. ■

۲.۳.۴ انتخاب پارامترها

پارامترهای اصلی روش TWAC و توصیه های انتخاب آن ها در جدول ۲.۴ آمده است.

۴.۴ مدیریت گره های گُند

در یک محیط ابری واقعی، برخی گره ها به دلیل محدودیت های محاسباتی یا شبکه ای نمی توانند پیش از پایان زمان مهلت پاسخ دهند. روش TWAC این موضوع را با دو مکانیزم مدیریت می کند:

۱.۴.۴ تعیین زمان مهلت تطبیقی

زمان مهلت $T_{\max}$ به صورت زیر تعیین می شود:

$$T_{\max}^t = \kappa \cdot \text{median}_{i \in S_t} (T_i^{\text{exp}}) \quad (12.4)$$

که T_i^{exp} زمان مورد انتظار برای گره i (بر اساس تاریخچه پاسخ دهی آن) و $\kappa > 1$ ضریب اطمینان است. انتخاب میانه به جای میانگین موجب می شود که گره های بسیار گُند (که ممکن است دچار خرابی موقت باشند) زمان مهلت را به شدت افزایش ندهند.

۲.۴.۴ کاهش تدریجی امتیاز اعتماد گره های گُند

برای گره هایی که در یک دور پاسخ نمی دهند ($i \in S_t \setminus R_t$)، امتیاز اعتماد با ضریب کوچکی کاهش می یابد:

$$\tau_i^t = \delta \cdot \tau_i^{t-1}, \quad \delta \in (0, 1) \quad (۱۳.۴)$$

انتخاب δ نزدیک به ۱ (مثلاً $\delta = 0.98$) موجب می‌شود که یک بار عدم پاسخ‌دهی تأثیر چندانی بر امتیاز اعتماد نداشته باشد، اما عدم پاسخ‌دهی مستمر امتیاز را به تدریج کاهش دهد.

مطالب بیشتر

این طراحی به این دلیل مهم است که در یک محیط ابری واقعی، یک مکث موقت (مثل یک garbage collection طولانی در ماشین مجازی یا یک اختلال گذرای شبکه) نباید موجب محرومیت دائمی گره از فرایند یادگیری شود. با $\delta = 0.98$ ، حتی ۵۰ دور عدم پاسخ‌دهی متوالی امتیاز را تنها به $0.36 \approx 0.98^{50}$ کاهش می‌دهد که هنوز بالاتر از $\tau_{\min}$ است.



۵.۴ تحلیل پیچیدگی

۱.۵.۴ پیچیدگی محاسباتی

در هر دور ارتباطی، اعمال زیر در سرور انجام می‌شود:

۱. محاسبه نرم به‌روزرسانی هر گره: $O(|R_t| \cdot d)$

۲. محاسبه میانه نرم‌ها: $O(|R_t| \log |R_t|)$

۳. محاسبه شباهت کسینوسی: $O(|R_t| \cdot d)$

۴. به‌روزرسانی امتیازات اعتماد: $O(|R_t|)$

۵. تجمیع وزن‌دار: $O(|R_t| \cdot d)$

۶. به‌روزرسانی جهت مرجع: $O(|R_t| \cdot d)$

بنابراین پیچیدگی کلی $O(|R_t| \cdot d) = O(Kd)$ است که با پیچیدگی FedAvg برابر است.

۲.۵.۴ مقایسه پیچیدگی

جدول ۲.۴ نشان می‌دهد که TWAC تنها روشی است که با پیچیدگی زمانی $O(nd)$ (برابر با FedAvg) قابلیت مقاوم‌سازی در برابر گره‌های مخرب را دارد. فضای اضافه $O(n)$ برای نگهداری امتیازات اعتماد و جهت مرجع صرف می‌شود که ناچیز است.

۶.۴ بحث در مورد نوآوری

۱.۶.۴ تفاوت با FedAvg

FedAvg با وزن دهی صرفاً بر اساس تعداد نمونه، هیچ تمایزی بین گره‌های صادق و مخرب قائل نمی‌شود. TWAC با جایگزینی این وزن دهی ساده با امتیازات اعتماد تاریخی، یک لایه امنیتی تطبیقی اضافه می‌کند.

۲.۶.۴ تفاوت با Krum و میانگین کوتاه‌شده

Krum و میانگین کوتاه‌شده هر دور را مستقل از دورهای قبل ارزیابی می‌کنند. این موجب می‌شود که یک به‌روزرسانی غیرعادی موقت (مثلاً ناشی از یک دسته داده نامتعادل) همان تأثیر منفی را داشته باشد که یک حمله واقعی. در TWAC، تاریخچه رفتار گره در ارزیابی آن نقش دارد، بنابراین یک خرابی گذرا تأثیر کمی دارد.

علاوه بر این، Krum پیچیدگی $O(n^2d)$ دارد که در محیط‌های ابری با هزینه مستقیم همراه است. TWAC با پیچیدگی $O(nd)$ ، یک ضریب $O(n)$ کمتر هزینه دارد.

۳.۶.۴ تفاوت با FLTrust

FLTrust نیز از مفهوم مشابهی استفاده می‌کند، اما به یک مجموعه داده اعتبارسنجی در سرور نیاز دارد. TWAC بدون هیچ داده اضافه‌ای در سرور، صرفاً بر اساس ساختار هندسی به‌روزرسانی‌های دریافتی و تاریخچه آن‌ها تصمیم می‌گیرد. سودوکد کامل الگوریتم TWAC در ۱ آمده است.

الگوریتم ۱ الگوریتم TWAC

Input: N nodes, K nodes per round, T rounds, hyperparameters $\gamma, \alpha, \beta, \mu, \tau_{\min}, \delta$.

Output: Global model w^T .

```

1: Initialize  $w^0$  randomly,  $\tau_i^0 = 1$  for all  $i$ ,  $\bar{\Delta}^0 = \mathbf{0}$ 
2: for  $t = 1, 2, \dots, T$  do
3:    $S_t \leftarrow$  select  $K$  nodes uniformly at random
4:   Broadcast  $w^t$  to all  $i \in S_t$ 
5:   Each node  $i \in S_t$  trains locally and computes  $\Delta_i^t$ 
6:    $R_t \leftarrow$  nodes that respond before timeout
7:   if  $|R_t| < K_{\min}$  then
8:     Skip round; continue
9:   end if
10:   $\text{med} \leftarrow \text{median}_{i \in R_t} (\|\Delta_i^t\|)$ 
11:  for each  $i \in R_t$  do
12:     $c_i^t \leftarrow \text{CosSim}(\Delta_i^t, \bar{\Delta}^{t-1})$ 
13:     $m_i^t \leftarrow \exp(-\alpha \cdot \max(0, \|\Delta_i^t\|/\text{med} - \beta))$ 
14:     $s_i^t \leftarrow \text{ReLU}(c_i^t) \cdot m_i^t$ 
15:     $\tau_i^t \leftarrow \gamma \cdot \tau_i^{t-1} + (1 - \gamma) \cdot s_i^t$ 
16:  end for
17:  for each  $i \in S_t \setminus R_t$  do
18:     $\tau_i^t \leftarrow \delta \cdot \tau_i^{t-1}$ 
19:  end for
20:   $\hat{\tau}_i^t \leftarrow \max(\tau_i^t, \tau_{\min})$  for all  $i \in R_t$ 
21:   $\hat{w}_i^t \leftarrow \hat{\tau}_i^t \cdot n_i / \sum_{j \in R_t} \hat{\tau}_j^t \cdot n_j$ 
22:   $w^{t+1} \leftarrow w^t + \sum_{i \in R_t} \hat{w}_i^t \cdot \Delta_i^t$ 
23:  Update  $\bar{\Delta}^t$  using Eq. (4.9)
24: end for
25: return  $w^T$ 

```

جدول ۱.۴: فهرست نمادهای استفاده شده در این فصل

نماد	توضیحات
N	تعداد کل گره‌های شرکت‌کننده
K	تعداد گره‌های انتخاب شده در هر دور
f	تعداد گره‌های مخرب
T	تعداد کل دورهای ارتباطی
t	شماره دور جاری
w^t	پارامترهای مدل سراسری در دور t
w_i^t	پارامترهای مدل محلی گره i پس از آموزش در دور t
Δ_i^t	به‌روزرسانی گره i در دور t ، برابر $w_i^t - w^t$
τ_i^t	امتیاز اعتماد گره i در دور t
$\bar{\Delta}^t$	جهت مرجع، میانگین متحرک نمایی به‌روزرسانی‌های تجمیع شده
S_t	مجموعه گره‌های انتخاب شده در دور t
$R_t \subseteq S_t$	مجموعه گره‌هایی که در دور t پاسخ دادند
γ	پارامتر اینرسی امتیاز اعتماد (ضریب EMA)
α	ضریب حساسیت مؤلفه بزرگی
β	آستانه تحمل بزرگی (مضربی از میانه)
μ	پارامتر اینرسی جهت مرجع
$\tau_{\min}$	حداقل امتیاز اعتماد مجاز (کف اعتماد)
δ	ضریب کاهش امتیاز گره‌های گُند
n_i	تعداد نمونه‌های داده گره i
d	تعداد پارامترهای مدل

جدول ۲.۴: پارامترهای روش TWAC و مقادیر پیشنهادی

نماد	توضیح	مقدار پیشنهادی	بازه مجاز
γ	اینرسی امتیاز اعتماد	0.7	[0.5, 0.9]
α	حساسیت بزرگی	2.0	[1.0, 5.0]
β	آستانه تحمل بزرگی	2.0	[1.5, 3.0]
μ	اینرسی جهت مرجع	0.9	[0.8, 0.95]
$\tau_{\min}$	کف اعتماد	0.1	[0.01, 0.2]
δ	ضریب کاهش گره کُند	0.98	[0.95, 0.99]

جدول ۳.۴: مقایسه پیچیدگی محاسباتی روش‌های مختلف تجميع

روش	پیچیدگی زمانی	پیچیدگی فضایی
FedAvg	$O(nd)$	$O(d)$
میان	$O(nd)$	$O(nd)$
میانگین کوتاه شده	$O(nd \log n)$	$O(nd)$
Krum	$O(n^2d)$	$O(n^2)$
Bulyan	$O(n^2d)$	$O(n^2)$
TWAC (این پژوهش)	$O(nd)$	$O(d + n)$

در این فصل، آزمایش‌های انجام‌شده برای ارزیابی روش پیشنهادی TWAC تشریح می‌شود. ابتدا در **بخش ۱.۵**، محیط آزمایش و تنظیمات پیاده‌سازی بیان می‌گردد. سپس در **بخش ۲.۵**، روش‌های مقایسه‌شده معرفی می‌شوند. در **بخش ۳.۵**، معیارهای سنجش کارایی تعریف می‌گردند. در **بخش ۴.۵**، چهار آزمایش اصلی این پژوهش و نتایج آن‌ها به تفصیل ارائه و تحلیل می‌شوند و در نهایت در **بخش ۵.۵**، جمع‌بندی نتایج ارائه می‌گردد.

۱.۵ محیط آزمایش و تنظیمات

۱.۱.۵ بستر نرم‌افزاری

تمام آزمایش‌ها روی یک ماشین واحد مجهز به کارت گرافیک پیاده‌سازی و اجرا شدند. شبیه‌سازی محیط ابری چندگانه به این شکل است که هر گره به صورت یک نمونه مستقل مدل‌سازی می‌شود که ویژگی‌های شبکه‌ای و محاسباتی متفاوتی دارد. پیاده‌سازی با استفاده از فریمورک PyTorch نسخه 2.0 انجام شده است. مشخصات بستر نرم‌افزاری آزمایش به شرح زیر است:

۲.۱.۵ مجموعه داده

در آزمایش‌های این پژوهش از مجموعه داده CIFAR-10¹ استفاده شده است. این مجموعه داده شامل ۵۰۰۰۰ تصویر آموزشی و ۱۰۰۰۰ تصویر آزمون در ۱۰ کلاس مجزا است. هر تصویر دارای ابعاد 32×32 پیکسل با سه کانال رنگی است. این مجموعه داده به دلایل زیر انتخاب شده است:

- ✓ چالش برانگیز بودن برای شبکه‌های کوچک، اما قابل آموزش در زمان معقول
- ✓ استاندارد بودن در ادبیات یادگیری فدرال که مقایسه با کارهای دیگر را ممکن می‌سازد
- ✓ امکان ایجاد توزیع‌های Non-IID واضح با روش دیریکله

¹Canadian Institute For Advanced Research

جدول ۵.۱: مشخصات بستر آزمایش

مقدار	مشخصه
NVIDIA GPU (CUDA enabled)	GPU
PyTorch 2.0	فریمورک
Python 3.10	زبان برنامه‌نویسی
NumPy, Matplotlib, PyYAML, scikit-learn	کتابخانه‌های جانبی

۳.۱.۵ مدل شبکه عصبی

مدل مورد استفاده یک شبکه عصبی پیچشی ساده (CNN^2) با معماری زیر است:

$\text{ReLU} \rightarrow \text{Conv2d}(3, 32, 3, \text{padding}=1)$ ✓

$\text{MaxPool}(2) \rightarrow \text{ReLU} \rightarrow \text{Conv2d}(32, 64, 3, \text{padding}=1)$ ✓

$\text{MaxPool}(2) \rightarrow \text{ReLU} \rightarrow \text{Conv2d}(64, 64, 3, \text{padding}=1)$ ✓

$\text{ReLU} \rightarrow \text{FC}(4096, 128)$ ✓

$\text{FC}(128, 10)$ ✓

این مدل دارای حدود ۵۸۲۰۰۰ پارامتر قابل آموزش است. انتخاب یک مدل نسبتاً کوچک به این دلیل است که هدف آزمایش‌ها مقایسه رفتار روش‌های تجمیع مختلف است، نه رسیدن به بالاترین دقت ممکن.

۴.۱.۵ توزیع داده میان گره‌ها

برای ایجاد توزیع Non-IID، از روش دیریکله با پارامتر α_{dir} استفاده شده است. بیست گره داریم و مجموعه آموزشی به گونه‌ای تقسیم می‌شود که هر گره سهمی از نمونه‌های هر کلاس دریافت کند که از توزیع $\text{Dir}(\alpha_{dir})$ نمونه‌برداری شده است. در آزمایش پایه، $\alpha_{dir} = 0.5$ انتخاب شده که ناهمگونی متوسطی ایجاد می‌کند؛ در آزمایش بررسی ناهمگونی داده، مقادیر دیگری نیز بررسی می‌شوند.

۵.۱.۵ تنظیمات یادگیری فدرال

تنظیمات پایه آزمایش‌ها در جدول ۲.۵ آمده است. این تنظیمات در همه آزمایش‌ها ثابت نگه داشته شده‌اند، مگر در مواردی که پارامتر مورد آزمایش (مثل α_{dir} یا درصد گره‌های مخرب) به صورت صریح تغییر کرده باشد.

²Convolutional Neural Network

جدول ۲.۵: تنظیمات پایه آزمایش‌های یادگیری فدرال

پارامتر	مقدار
تعداد گره‌ها (N)	20
گره‌های انتخابی در هر دور (K)	10
تعداد دورهای ارتباطی (T)	100
دوره‌های آموزش محلی (E)	5
نرخ یادگیری محلی (η)	0.01
اندازه دسته	32
پارامتر دیریکله پایه (α_{dir})	0.5
بذر تصادفی	42

۶.۱.۵ شبیه‌سازی ناهمگونی

۱.۶.۱.۵ ناهمگونی محاسباتی

هر گره یک ضریب سرعت محاسباتی s_i دارد که به صورت یکنواخت از بازه $[0.3, 1.0]$ نمونه‌برداری شده است. این ضریب زمان شبیه‌سازی شده برای آموزش محلی را تعیین می‌کند و موجب می‌شود همه گره‌ها در یک دور به طور هم‌زمان آموزش خود را به پایان نرسانند.

۲.۶.۱.۵ ناهمگونی شبکه و گره‌های گُند

برای آزمایش مدیریت گره‌های گُند، درصد معینی از گره‌ها به عنوان گره گُند تعیین می‌شوند. این گره‌ها علاوه بر سرعت محاسباتی پایین، ضریب گُند شدن شبکه‌ای نیز دارند که در شبیه‌سازی به صورت ضریب گُندی $3 \times$ نسبت به گره‌های عادی مدل‌سازی شده است؛ به این معنا که این گره‌ها زمان بسیار بیشتری برای پاسخ‌گویی در هر دور ارتباطی نیاز دارند.

۲.۵ روش‌های مورد مقایسه

در تمام آزمایش‌ها، روش TWAC با سه روش پایه مقایسه می‌شود:

۱. FedAvg: الگوریتم استاندارد میانگین‌گیری فدرال بدون هیچ مکانیزم دفاعی.

۲. میانگین کوتاه‌شده (TrimmedMean): در هر مختصه، 20% از بزرگ‌ترین و کوچک‌ترین مقادیر حذف می‌شود.

۳. Multi-Krum: در هر دور، 5 گره با کمترین امتیاز Krum انتخاب می‌شوند و میانگین وزن‌دار آن‌ها محاسبه می‌شود.

هر چهار روش از یک کد پایه مشترک، یک مدل یکسان، و یک بذر تصادفی یکسان استفاده می‌کنند تا مقایسه تا حد امکان منصفانه باشد. تنها بخش متفاوت میان آن‌ها، الگوریتم تجمیع در سرور است.

۳.۵ معیارهای سنجش کارایی

۱.۳.۵ دقت آزمون نهایی و بهترین دقت

دو معیار اصلی گزارش شده برای هر آزمایش، دقت آزمون در آخرین دور (Acc^T)، که از این پس «دقت نهایی» نامیده می‌شود و بالاترین دقت آزمون مشاهده شده در طول کل آموزش («بهترین دقت») هستند:

$$\text{Acc}^t = \frac{1}{|\mathcal{D}_{test}|} \sum_{(x,y) \in \mathcal{D}_{test}} \mathbf{1}[\arg \max f(x; w^t) = y] \quad (۱.۵)$$

گزارش هر دو معیار به این دلیل مفید است که دقت نهایی منعکس‌کننده وضعیت مدل در پایان بودجه ارتباطی مشخص شده است، در حالی که بهترین دقت نشان می‌دهد روش تا چه حد توانسته در طول مسیر آموزش به یک نقطه مطلوب برسد (حتی اگر در دور آخر کمی افت داشته باشد).

۲.۳.۵ خطای آزمون نهایی

خطای آزمون با استفاده از تابع خطای اینتروپی متقاطع محاسبه می‌شود:

$$\mathcal{L}^t = -\frac{1}{|\mathcal{D}_{test}|} \sum_{(x,y) \in \mathcal{D}_{test}} \log f_y(x; w^t) \quad (۲.۵)$$

۳.۳.۵ زمان اجرا

برای هر آزمایش، زمان کل اجرای فرایند آموزش (بر حسب ثانیه) نیز ثبت شده است. این معیار به‌طور مستقیم پیچیدگی محاسباتی عملی هر روش تجمیع را نشان می‌دهد و امکان مقایسه هزینه واقعی TWAC با Multi-Krum را، که از نظر نظری پیچیدگی بسیار بالاتری دارد، فراهم می‌کند.

۴.۵ آزمایش‌ها و تحلیل نتایج

چهار آزمایش اصلی این پژوهش، به ترتیب، رفتار پایه روش‌ها بدون حمله، مقاومت در برابر حمله جهت‌معکوس‌سازی در دو سطح شدت، تأثیر درجه ناهمگونی داده، و مقاومت در برابر گره‌های گُند را بررسی می‌کنند. در همه آزمایش‌ها، تنظیمات جدول ۲.۵ به‌عنوان پایه استفاده شده و تنها پارامتر مورد بررسی هر آزمایش تغییر کرده است.

جدول ۳.۵: نتایج آزمایش پایه (بدون حمله، $\alpha_{dir} = 0.5$)

روش	دقت نهایی	بهترین دقت	خطای نهایی	زمان اجرا
FedAvg	80.12%	80.12%	0.7066	2454.3 ثانیه
میانگین کوتاه‌شده	79.29%	79.71%	0.7100	2421.7 ثانیه
Multi-Krum	74.94%	76.74%	1.0108	2413.4 ثانیه
TWAC	80.06%	80.11%	0.6927	2411.3 ثانیه

۱.۴.۵ آزمایش ۱: مقایسه پایه (بدون حمله)

در این آزمایش، هیچ گره مخربی وجود ندارد و هدف مقایسه رفتار پایه روش‌های مختلف در شرایط عادی محیط ابری چندگانه (با ناهمگونی محاسباتی و $\alpha_{dir} = 0.5$) است.


نتایج جدول ۳.۵ چند نکته مهم را نشان می‌دهد. نخست، در نبود هرگونه حمله، TWAC عملکردی تقریباً معادل FedAvg دارد (80.06% در مقابل 80.12% دقت نهایی)، با این تفاوت که خطای نهایی TWAC (0.6927) اندکی بهتر از FedAvg (0.7066) است. این نتیجه با انتظار طراحی روش همخوانی دارد: در شرایط عادی که همه گره‌ها صادق هستند، مکانیزم اعتماد نباید جریمه قابل توجهی به سیستم تحمیل کند، و نتایج تأیید می‌کنند که این هدف برآورده شده است.

دوم، Multi-Krum حتی در این سناریوی بدون حمله، پایین‌ترین دقت (74.94%) را دارد. این به دلیل محدودیت ذاتی Krum است: این روش تنها 5 گره از میان 10 گره منتخب هر دور را برای تجمیع انتخاب می‌کند و از اطلاعات نیمی از گره‌های صادق صرف‌نظر می‌کند، که موجب کاهش کیفیت یادگیری حتی در نبود حمله می‌شود.

سوم، از نظر زمان اجرا، چهار روش تفاوت چشمگیری ندارند (2411 تا 2454 ثانیه). این مشاهده در آزمایش حاضر، که با 20 گره و ابعاد مدل نسبتاً کوچک (≈ 582000 پارامتر) انجام شده، نشان می‌دهد که در این مقیاس، هزینه غالب اجرا صرف آموزش محلی روی گره‌ها می‌شود، نه الگوریتم تجمیع در سرور. با این حال، تحلیل نظری پیچیدگی (بخش ۵.۴) همچنان نشان می‌دهد که با افزایش تعداد گره‌ها یا ابعاد مدل، شکاف میان Multi-Krum با پیچیدگی $O(n^2d)$ و TWAC با پیچیدگی $O(nd)$ بیشتر خواهد شد. شکل ۱.۵ روند تغییرات دقت و خطا در طول 100 دور ارتباطی را نشان می‌دهد. مشاهده می‌شود که منحنی دقت TWAC و FedAvg عملاً بر هم منطبق‌اند، در حالی که منحنی Multi-Krum از همان دوره‌های ابتدایی فاصله خود را با دو روش دیگر حفظ می‌کند. در نمودار رفتار امتیاز اعتماد، چون در این آزمایش هیچ گره مخربی وجود ندارد، امتیازات اعتماد همه گره‌ها پس از چند دور ابتدایی به مقادیر بالا (نزدیک به یک) همگرا می‌شوند، که با تحلیل نظری ارائه‌شده در قضیه ۲.۴ همخوانی دارد.

۲.۴.۵ آزمایش ۲: مقاومت در برابر حمله جهت‌معکوس‌سازی

حمله جهت‌معکوس‌سازی (Sign-Flip) یکی از خطرناک‌ترین حملات بی‌زانتین است، چون به‌روزرسانی مخرب می‌تواند از نظر بزرگی کاملاً مشابه به‌روزرسانی‌های صادق باشد و تنها از نظر جهت با آن‌ها تفاوت داشته باشد. در این آزمایش، عملکرد چهار روش در دو سطح شدت حمله (20% و 30% گره‌های مخرب) بررسی شده است.



شکل ۱.۵: خلاصه گرافیکی آزمایش پایه: روند دقت آزمون، روند خطای آزمون، دقت نهایی چهار روش، و رفتار امتیاز اعتماد TWAC در طول دوره‌های ارتباطی

نتایج جدول‌های ۴.۵ و ۵.۵ چند نکته را روشن می‌کنند. در هر دو سطح شدت حمله، TWAC بالاترین دقت نهایی را در میان چهار روش دارد؛ در سطح 20% حمله، دقت 74.46% در مقابل 73.42% برای FedAvg و 68.89% برای Multi-Krum است. در سطح 30% حمله، فاصله میان روش‌ها کاهش می‌یابد ولی TWAC (73.58%) همچنان جلوتر از FedAvg (73.17%) و میانگین کوتاه‌شده (73.51%) باقی می‌ماند.

نکته قابل توجه دیگر این است که در این آزمایش، با مدل پیچشی نسبتاً کوچک و 20 گره، افت دقت FedAvg نسبت به سناریوی بدون حمله محدود است (از 80.12% در آزمایش پایه به حدود 73% در حضور حمله)، که نشان می‌دهد در این مقیاس، خود فرایند میانگین‌گیری وزن‌دار بر اساس تعداد نمونه تا حدی اثر گره‌های مخرب را با اثر گره‌های صادق دیگر کم‌رنگ می‌کند؛ اما همچنان TWAC با شناسایی فعال این گره‌ها از طریق مؤلفه همسویی جهتی، در هر دو سطح حمله برتری پایدار خود را حفظ می‌کند. همچنین مشاهده می‌شود که Multi-Krum در سطح 20% حمله ضعیف‌ترین عملکرد را دارد، در حالی که در سطح 30% بهبود نسبی نشان می‌دهد؛ این رفتار با حساسیت بالای انتخاب m گره ثابت در Krum به نسبت دقیق گره‌های صادق به مخرب در هر دور قابل توضیح است.

شکل ۲.۵ روند کاهش دقت هر روش را با افزایش درصد گره‌های مخرب در یک نگاه نشان می‌دهد. می‌توان مشاهده کرد که شیب کاهش دقت Multi-Krum از 0% به 20% حمله، تندتر از سایر روش‌هاست؛ این روش که خودش برای مقاومت در برابر بی‌زانتین طراحی شده، در این آزمایش مشخص با مقیاس کوچک حساسیت بیشتری نسبت به TWAC و میانگین کوتاه‌شده نشان می‌دهد. ستون TWAC در هر سه سطح حمله، بالاترین یا نزدیک به بالاترین مقدار را دارد.

جدول ۴.۵: نتایج آزمایش حمله جهت معکوس سازی با 20% گره مخرب

روش	دقت نهایی	بهترین دقت	خطای نهایی	زمان اجرا
FedAvg	73.42%	75.49%	1.1986	2276.6 ثانیه
میانگین کوتاه شده	73.88%	75.35%	1.1164	2283.3 ثانیه
Multi-Krum	68.89%	71.95%	1.6249	2276.5 ثانیه
TWAC	74.46%	75.73%	1.1244	2273.6 ثانیه

جدول ۵.۵: نتایج آزمایش حمله جهت معکوس سازی با 30% گره مخرب


روش	دقت نهایی	بهترین دقت	خطای نهایی	زمان اجرا
FedAvg	73.17%	75.35%	1.1656	2282.9 ثانیه
میانگین کوتاه شده	73.51%	74.61%	1.1476	2290.5 ثانیه
Multi-Krum	71.23%	72.69%	1.2331	2285.9 ثانیه
TWAC	73.58%	75.73%	1.2089	2279.6 ثانیه

۳.۴.۵ آزمایش ۳: تأثیر ناهمگونی داده

در این آزمایش، درجه ناهمگونی داده با تغییر پارامتر α_{dir} تحت شرایط بدون حمله بررسی می‌شود. دو مقدار $\alpha_{dir} = 0.1$ (ناهمگونی شدید، هر گره عمدتاً نمونه‌های یک یا دو کلاس دارد) و $\alpha_{dir} = 1.0$ (ناهمگونی نسبتاً ملایم) آزمایش شده‌اند.

نتایج جدول ۶.۵ نشان می‌دهند که در ناهمگونی شدید ($\alpha_{dir} = 0.1$)، Multi-Krum با دقت 49.84% به شدت آسیب می‌بیند. علت این افت شدید آن است که در ناهمگونی بالا، حتی به‌روزرسانی‌های گره‌های صادق نیز می‌توانند از نظر هندسی با یکدیگر فاصله زیادی داشته باشند (چون هر گره داده‌های بسیار متفاوتی دارد)؛ در نتیجه، معیار «نزدیکی به همسایگان» که برای تشخیص گره‌های مخرب به کار می‌برد، در این شرایط به اشتباه برخی گره‌های کاملاً صادق را کنار می‌گذارد. TWAC (70.11%) و میانگین کوتاه شده (70.41%) در این سناریو بسیار نزدیک به هم عمل می‌کنند و هر دو به وضوح بهتر از FedAvg (65.95%) هستند؛ این نشان می‌دهد که هر دو مکانیزم، با وجود تفاوت در طراحی، در برابر ناهمگونی شدید بدون حمله، رفتار محافظه کارانه‌ای دارند که از واگرایی شدید مدل سراسری جلوگیری می‌کند.

در ناهمگونی ملایم‌تر ($\alpha_{dir} = 1.0$)، جدول ۷.۵، تفاوت میان چهار روش بسیار کوچک‌تر است؛ FedAvg دقت نهایی کمی بالاتر دارد (81.41%)، اما TWAC بهترین دقت مشاهده شده در طول آموزش را به خود اختصاص می‌دهد (82.29%). Multi-Krum در این حالت نیز همچنان ضعیف‌ترین روش است، اگرچه فاصله‌اش با سایر روش‌ها در مقایسه با حالت $\alpha_{dir} = 0.1$ بسیار کمتر شده است. این دو آزمایش با هم نشان می‌دهند که هرچه ناهمگونی داده شدیدتر شود، تفاوت میان روش‌های تجمیع پرمعنی‌تر می‌شود. شکل ۳.۵ روند همگرایی چهار روش را در سناریوی ناهمگونی شدید داده نشان می‌دهد. منحنی Multi-Krum نه تنها به دقت



شکل ۲.۵: مقایسه دقت نهایی چهار روش در سه سطح حمله جهت معکوس‌سازی: بدون حمله، 20% و 30% گره مخرب

جدول ۶.۵: نتایج آزمایش ناهمگونی شدید داده ($\alpha_{dir} = 0.1$)

روش	دقت نهایی	بهترین دقت	خطای نهایی	زمان اجرا
FedAvg	65.95%	72.30%	1.1979	2211.5 ثانیه
میانگین کوتاه‌شده	70.41%	72.99%	0.9147	2214.2 ثانیه
Multi-Krum	49.84%	58.27%	1.8193	2209.4 ثانیه
TWAC	70.11%	72.98%	0.9740	2329.8 ثانیه

پایین‌تری همگرا می‌شود، بلکه در طول آموزش نوسانات بیشتری نیز نسبت به سایر روش‌ها از خود نشان می‌دهد؛ این نوسان با ناپایداری معیار «نزدیکی به همسایگان» در شرایط ناهمگونی شدید (که در تحلیل جدول ۶.۵ توضیح داده شد) همخوانی دارد. در مقابل، منحنی‌های TWAC و میانگین کوتاه‌شده روندی صاف‌تر و پایدارتر دارند.


۴.۴.۵ آزمایش ۴: مقاومت در برابر گره‌های گند

در این آزمایش، 40% از گره‌ها به‌عنوان گره گند تعریف شده‌اند که علاوه بر سرعت محاسباتی کمتر، تأخیر شبکه‌ای سه‌برابری نیز دارند.

در این سناریو، FedAvg دقت نهایی کمی بالاتری نسبت به TWAC دارد (80.55% در مقابل 80.43%)، اما TWAC پایین‌ترین خطای نهایی (0.6661) را در میان چهار روش به دست می‌آورد. تفاوت دقت میان این دو روش بسیار کوچک است (0.12 واحد درصد) و در عمل می‌توان آن‌ها را قابل مقایسه دانست. نکته مهم‌تر این است که Multi-Krum در این سناریو ضعیف‌ترین عملکرد (78.02%) را دارد؛ زیرا با حذف کامل گره‌های انتخاب‌نشده در هر دور و اتکا بر زیرمجموعه‌ای کوچک از گره‌های پاسخ‌دهنده، اطلاعات گره‌های گندی را که هنوز داده‌های منحصر به فردی دارند، به‌طور کامل از دست می‌دهد. در مقابل، مکانیزم کاهش تدریجی امتیاز اعتماد در

جدول ۷.۵: نتایج آزمایش ناهمگونی ملایم داده ($\alpha_{dir} = 1.0$)

روش	دقت نهایی	بهترین دقت	خطای نهایی	زمان اجرا
FedAvg	81.41%	82.13%	0.6581	2375.7 ثانیه
میانگین کوتاه‌شده	81.21%	81.75%	0.6434	2417.7 ثانیه
Multi-Krum	79.57%	79.57%	0.7403	2454.0 ثانیه
TWAC	81.09%	82.29%	0.6834	2555.2 ثانیه

شکل ۳.۵: روند دقت آزمون چهار روش در طول دوره‌های ارتباطی تحت ناهمگونی شدید داده ($\alpha_{dir} = 0.1$)


TWAC (معادله (۱۳.۴)) به گونه‌ای طراحی شده که گره‌های کُند را به‌طور کامل از فرایند یادگیری حذف نمی‌کند، بلکه با وزن کمتر اجازه مشارکت می‌دهد؛ این رویکرد محافظه‌کارانه در این آزمایش به نتیجه‌ای نزدیک به FedAvg منجر شده است، بدون آنکه هزینه نظری مدیریت گره کُند نادیده گرفته شود.

لازم به ذکر است که زمان اجرای TWAC در این آزمایش (2680.3 ثانیه) به‌طور نسبی بالاتر از سایر روش‌ها است؛ این تفاوت ناشی از سربار محاسبه میانه زمان پاسخ‌دهی برای تعیین زمان مهلت تطبیقی (معادله (۱۲.۴)) و نگهداری امتیازات اعتماد در طول دوره‌های متعدد گره‌های کُند است، اگرچه این سربار در مقیاس بزرگ همچنان از مرتبه $O(n)$ و قابل چشم‌پوشی است.

شکل ۴.۵ روند خطای آزمون را در طول آموزش نشان می‌دهد. منحنی خطای TWAC از دوره‌های میانی به بعد به‌طور پیوسته پایین‌تر از FedAvg و میانگین کوتاه‌شده قرار می‌گیرد، که با مقدار خطای نهایی پایین‌تر گزارش‌شده در جدول ۸.۵ همخوانی دارد. این مشاهده نشان می‌دهد که با وجود دقت نهایی تقریباً مشابه با FedAvg، مدل به‌دست‌آمده توسط TWAC از نظر اطمینان پیش‌بینی (که در تابع خطای اینتروپی متقاطع منعکس می‌شود) اندکی برتر است.

جدول ۸.۵: نتایج آزمایش مقاومت در برابر گره‌های کُند (40% گره کُند)

روش	دقت نهایی	بهترین دقت	خطای نهایی	زمان اجرا
FedAvg	80.55%	80.55%	0.6797	2458.0 ثانیه
میانگین کوتاه‌شده	80.38%	80.38%	0.6870	2459.2 ثانیه
Multi-Krum	78.02%	78.02%	0.8891	2503.5 ثانیه
TWAC	80.43%	80.43%	0.6661	2680.3 ثانیه



شکل ۴.۵: روند خطای آزمون چهار روش در طول دوره‌های ارتباطی تحت سناریوی 40% گره کُند

۵.۵ جمع‌بندی نتایج

جدول ۹.۵ مجموع نتایج شش سناریوی آزمایشی را در یک نگاه نمایش می‌دهد. نکات کلیدی که از مجموع این نتایج می‌توان استخراج کرد به شرح زیر است:

✓ **رفتار در غیاب حمله:** TWAC در سناریوی پایه عملکردی تقریباً برابر با FedAvg دارد (80.06% در مقابل 80.12%) و خطای نهایی کمی بهتر کسب می‌کند. این نتیجه نشان می‌دهد که اضافه کردن مکانیزم اعتماد، هزینه‌ای در شرایط عادی به سیستم تحمیل نمی‌کند.

✓ **مقاومت در برابر حمله جهت معکوس‌سازی:** TWAC در هر دو سطح 20% و 30% گره مخرب، بالاترین دقت نهایی را در میان چهار روش دارد، اگرچه فاصله آن با FedAvg در این آزمایش‌ها محدود (کمتر از یک واحد درصد تا حدود یک واحد درصد) است.

جدول ۹.۵: جمع‌بندی دقت نهایی همه آزمایش‌ها

سناریو	FedAvg	TrimMean	Krum	TWAC
پایه، $\alpha_{dir} = 0.5$ (بدون حمله)	80.12%	79.29%	74.94%	80.06%
حمله جهت معکوس (20%)	73.42%	73.88%	68.89%	74.46%
حمله جهت معکوس (30%)	73.17%	73.51%	71.23%	73.58%
ناهمگونی شدید ($\alpha_{dir} = 0.1$)	65.95%	70.41%	49.84%	70.11%
ناهمگونی ملایم ($\alpha_{dir} = 1.0$)	81.41%	81.21%	79.57%	81.09%
گره کُند (40%)	80.55%	80.38%	78.02%	80.43%

✓ **ناهمگونی داده:** در ناهمگونی شدید ($\alpha_{dir} = 0.1$)، TWAC و میانگین کوتاه‌شده عملکردی نزدیک به هم و به‌وضوح بهتر از FedAvg و Multi-Krum دارند. Multi-Krum در این سناریو بیشترین آسیب را می‌بیند که نشان‌دهنده حساسیت بالای این روش به ناهمگونی شدید داده است.

✓ **گره‌های کُند:** Multi-Krum در هر دو سناریوی ناهمگونی داده و گره‌های کُند، ضعیف‌ترین عملکرد را دارد. در سناریوی گره کُند، TWAC با کاهش تدریجی اعتماد به جای حذف کامل، نتیجه‌ای نزدیک به FedAvg و بهتر از Multi-Krum به دست می‌آورد.

✓ **روند کلی:** در میان چهار روش، Multi-Krum در پنج از شش سناریو ضعیف‌ترین عملکرد را دارد، که با پیچیدگی محاسباتی بالاتر آن ($O(n^2d)$) نیز همراه است. TWAC و میانگین کوتاه‌شده در بیشتر سناریوها رقابتی نزدیک دارند، با این تفاوت که TWAC پیچیدگی محاسباتی پایین‌تری ($O(nd)$)، برابر با FedAvg دارد و علاوه بر این، تنها روشی است که به‌طور هم‌زمان از حافظه اعتماد تاریخی و مدیریت تطبیقی گره‌های کُند بهره می‌برد.

نکته

تفاوت‌های دقت گزارش‌شده در این آزمایش‌ها (معمولاً در بازه نیم تا چند واحد درصد، به‌استثنای سناریوی ناهمگونی شدید) بر اساس یک اجرای منفرد برای هر پیکربندی به‌دست آمده‌اند. تکرار آزمایش‌ها با بذره‌ای تصادفی متفاوت و گزارش میانگین و انحراف معیار، گام طبیعی بعدی برای افزایش استحکام آماری این نتایج است که در بخش ۲.۶ به آن اشاره خواهد شد.



۶ نتیجه‌گیری و کارهای آینده

در این فصل نخست در بخش ۱.۶، مروری بر آنچه در این پژوهش انجام شد صورت می‌پذیرد و نتایج اصلی جمع‌بندی می‌شوند. در ادامه نیز در بخش ۲.۶، مسائل باز این حوزه و پیشنهاداتی برای کارهای آینده ارائه خواهد شد.

۱.۶ نتیجه‌گیری

این پژوهش به مسئله یادگیری فدرال در محیط‌های ابری چندگانه ناهمگون پرداخت. این محیط‌ها با سه چالش اساسی مشخص می‌شوند: ناهمگونی محاسباتی (تفاوت در توان پردازشی نمونه‌های ابری)، ناهمگونی شبکه (تفاوت در تأخیر و پهنای باند ارتباطات بین ناحیه‌ای)، و ناهمگونی داده (توزیع Non-IID داده‌های محلی). علاوه بر این، در محیط‌های ابری واقعی احتمال وجود گره‌های معیوب یا مخرب نیز وجود دارد.

روش‌های موجود یا تنها یکی از این چالش‌ها را هدف می‌گیرند، یا برای حل همزمان آن‌ها هزینه محاسباتی سنگینی دارند. در این پژوهش، مکانیزم TWAC پیشنهاد شد که با طراحی یکپارچه به همه این چالش‌ها پاسخ می‌دهد.

۱.۱.۶ خلاصه روش پیشنهادی

TWAC برای هر گره یک امتیاز اعتماد نگهداری می‌کند که در هر دور ارتباطی بر اساس دو مؤلفه به‌روز می‌شود. مؤلفه همسویی جهتی، شباهت کسینوسی به‌روزرسانی گره را با میانگین متحرک نمایی جهت تجمیع شده‌های گذشته اندازه می‌گیرد. مؤلفه بزرگی منطقی، نرم به‌روزرسانی را نسبت به میانه نرم‌های همه گره‌ها ارزیابی می‌کند. ترکیب این دو مؤلفه گره‌هایی را که جهت معکوس‌سازی انجام می‌دهند (از طریق مؤلفه اول) یا نرم‌های غیرعادی بزرگ دارند (از طریق مؤلفه دوم) شناسایی می‌کند. امتیازات اعتماد با میانگین متحرک نمایی به‌روز می‌شوند که موجب می‌شود تأثیر رفتار گذرا کمتر باشد و رفتار مستمر وزن بیشتری در ارزیابی داشته باشد.

برای مدیریت گره‌های گُند، زمان مهلت تطبیقی بر اساس میانه زمان‌های پاسخ تعیین می‌شود و گره‌هایی که پاسخ نمی‌دهند، امتیاز اعتمادشان با یک ضریب کوچک کاهش می‌یابد. این طراحی از محرومیت دائمی گره‌هایی که به دلیل مشکلات گذرا در یک دور پاسخ ندادند جلوگیری می‌کند.

۲.۱.۶ خلاصه نتایج آزمایشی

آزمایش‌ها در شش سناریوی متفاوت روی مجموعه داده CIFAR-۱۰ با بیست گره انجام شد. نتایج به‌طور خلاصه عبارتند از:

✓ در سناریوی پایه (بدون حمله، $\alpha_{dir} = 0.5$)، TWAC با دقت 80.06% عملکردی تقریباً برابر با FedAvg، با دقت 80.12%، دارد و از نظر خطای نهایی (0.6927 در مقابل 0.7066) اندکی بهتر است. این نشان می‌دهد که مکانیزم اعتماد در شرایط عادی هزینه‌ای به سیستم تحمیل نمی‌کند.

✓ در برابر حمله جهت‌معکوس‌سازی با 20% گره مخرب، TWAC با دقت 74.46% بالاترین دقت را در میان چهار روش دارد و از FedAvg (73.42%) و Multi-Krum (68.89%) پیشی می‌گیرد. این برتری در سطح 30% حمله نیز (73.58% در مقابل 73.17% برای FedAvg) حفظ می‌شود.

✓ در سناریوی ناهمگونی شدید داده ($\alpha_{dir} = 0.1$)، TWAC با دقت 70.11% و میانگین کوتاه‌شده با دقت 70.41% هر دو به‌وضوح بهتر از FedAvg (65.95%) و به‌خصوص Multi-Krum (49.84%) عمل می‌کنند. Multi-Krum در این سناریو بیشترین آسیب‌پذیری را در برابر ناهمگونی شدید داده نشان می‌دهد.

✓ در سناریوی گره‌های کُند (40%)، TWAC با دقت 80.43% نتیجه‌ای نزدیک به FedAvg (80.55%) و بهتر از Multi-Krum (78.02%) به دست می‌آورد، در حالی که پایین‌ترین خطای نهایی را در میان چهار روش دارد.

✓ در تمام آزمایش‌ها، زمان اجرای TWAC از همان مرتبه زمان اجرای FedAvg است که با تحلیل نظری پیچیدگی $O(nd)$ این روش همخوانی دارد. Multi-Krum، با وجود پیچیدگی نظری بالاتر ($O(n^2d)$)، در این مقیاس آزمایشی (20 گره) از نظر زمان اجرا تفاوت چشمگیری با سایر روش‌ها نداشت؛ اما در پنج از شش سناریو، از نظر دقت ضعیف‌ترین روش بود.

۳.۱.۶ بحث در مورد محدودیت‌ها

با وجود نتایج مثبت، چند محدودیت در این پژوهش وجود دارد که باید صادقانه بیان شوند. نخست، ارزیابی روی یک مجموعه داده واحد (CIFAR-۱۰) انجام شده است و تعمیم‌پذیری نتایج به سایر حوزه‌ها نیاز به بررسی بیشتر دارد. دوم، آزمایش‌های تجربی این پژوهش متمرکز بر حمله جهت‌معکوس‌سازی، ناهمگونی داده و گره‌های کُند بوده‌اند؛ ارزیابی عملی مکانیزم TWAC در برابر حملات نوین تصادفی و مقیاس‌افزایی، که در [بخش ۳.۲](#) به‌صورت نظری معرفی شدند، در محدوده آزمایش‌های حاضر قرار نگرفته است. سوم، نتایج گزارش‌شده در [فصل ۵](#) بر اساس یک اجرای منفرد برای هر پیکربندی به‌دست آمده‌اند و فاقد تکرار آماری با بذره‌های تصادفی متعدد هستند؛ به‌ویژه در سناریوهایی که فاصله دقت میان روش‌ها کم است (مانند سناریوهای ناهمگونی ملایم و گره کُند)، تکرار آزمایش‌ها برای اطمینان از معناداری آماری این تفاوت‌ها ضروری است. چهارم، فرض کفایت امتیاز اعتماد برای تشخیص گره‌های مخرب ممکن است در برابر حملات پیچیده‌تری که به‌طور دقیق رفتار گره‌های صادق را تقلید می‌کنند (مثل حملات بک‌دور) کارساز نباشد. پنجم، انتخاب مقادیر بهینه پارامترهایی مثل γ و β ممکن است در سناریوهای مختلف متفاوت باشد و در این پژوهش با مقادیر ثابت آزمایش شده‌اند.

۲.۶ کارهای آینده

بر اساس نتایج و محدودیت‌های پژوهش حاضر، جهت‌های زیر برای تحقیقات آینده پیشنهاد می‌شود:

۱.۲.۶ تکرار آماری و تکمیل سناریوهای حمله

گام نخست و ساده‌ترین کار آینده، تکرار هر یک از شش سناریوی آزمایشی این پژوهش با چندین بذر تصادفی مختلف و گزارش میانگین و انحراف معیار دقت است؛ این کار به‌خصوص برای سناریوهایی که فاصله دقت میان روش‌ها کم بود (مانند ناهمگونی ملایم و گرگ‌گند) اهمیت دارد. علاوه بر این، ارزیابی عملی TWAC در برابر حمله نویز تصادفی و حمله مقیاس‌افزایی، که در این پژوهش تنها در سطح نظری بررسی شدند، تصویر کامل‌تری از مقاومت این روش ارائه خواهد داد.

۲.۲.۶ گسترش به مجموعه داده‌های بزرگ‌تر

یک گام طبیعی بعدی، ارزیابی TWAC روی مجموعه داده‌های بزرگ‌تر مثل ImageNet یا FEMNIST است. در FEMNIST که یک مجموعه داده فدرال واقعی است، ناهمگونی داده ذاتاً وجود دارد و نیازی به شبیه‌سازی مصنوعی ندارد.

۳.۲.۶ مقاوم‌سازی در برابر حملات پیچیده‌تر

حملات بک‌دور (Backdoor Attack) [۱۶] نوعی از حملات هستند که در آن‌ها گرگ مخرب به‌گونه‌ای عمل می‌کند که مدل روی اکثر داده‌ها درست رفتار کند، اما روی یک زیرمجموعه خاص (مثلاً تصاویر با یک نشان خاص) رفتار مخرب داشته باشد. کشف اینکه آیا مکانیزم امتیاز اعتماد TWAC می‌تواند این نوع حملات را نیز شناسایی کند، جهت جالبی برای پژوهش آینده است.

۴.۲.۶ انتخاب تطبیقی پارامترها

در حال حاضر پارامترهای TWAC (مثل α ، β ، γ) به‌صورت ثابت تنظیم می‌شوند. یک پیشرفت احتمالی، طراحی مکانیزمی برای تنظیم خودکار این پارامترها بر اساس خصوصیات مشاهده‌شده در هر دور است. مثلاً γ می‌تواند در دورهای ابتدایی کوچک‌تر باشد (تا امتیازات سریع‌تر همگرا شوند) و در دورهای بعدی بزرگ‌تر (تا پایداری بیشتری داشته باشند).

۵.۲.۶ ترکیب با فشرده‌سازی ارتباطی

در محیط‌های ابری با پهنای باند محدود، فشرده‌سازی به‌روزرسانی‌های مدل می‌تواند هزینه ارتباطی را کاهش دهد. بررسی سازگاری TWAC با روش‌های فشرده‌سازی مثل کوانتیزاسیون (Quantization) یا درندگی (Sparsification) و اینکه آیا فشرده‌سازی بر کیفیت امتیازات اعتماد تأثیر می‌گذارد، یک سؤال تحقیقاتی جالب است.

۶.۲.۶ پیاده‌سازی توزیع‌شده واقعی

پیاده‌سازی فعلی یک شبیه‌سازی روی یک ماشین است. یک گام مهم، پیاده‌سازی TWAC در یک بستر توزیع‌شده واقعی مثل Flower یا PySyft و ارزیابی آن در یک محیط ابری چندگانه واقعی است. این پیاده‌سازی می‌تواند جنبه‌هایی از رفتار سیستم را آشکار کند که در شبیه‌سازی قابل مشاهده نیستند.

۷.۲.۶ تعمیم به یادگیری فدرال بدون سرور مرکزی

در پیکربندی فعلی، یک سرور مرکزی برای تجمیع وجود دارد. یادگیری فدرال بدون سرور مرکزی (Decentralized FL) که در آن گره‌ها مستقیماً با یکدیگر ارتباط برقرار می‌کنند، چالش جالبی برای تعمیم مفهوم امتیاز اعتماد ایجاد می‌کند. در این حالت، هر گره باید امتیاز اعتماد همسایگان خود را به‌صورت محلی نگهداری کند.

خلاصه کارهای آینده

کارهای پیشنهادی برای آینده را می‌توان در سه دسته کلی تقسیم‌بندی کرد: (الف) گسترش ارزیابی تجربی به مجموعه داده‌ها و سناریوهای حمله متنوع‌تر، (ب) بهبود الگوریتمی از طریق انتخاب تطبیقی پارامترها و ترکیب با فشرده‌سازی ارتباطی، و (ج) گسترش معماری به سمت سیستم‌های غیرمتمرکز و پیاده‌سازی واقعی در محیط‌های ابری.



- [1] P. Blanchard, E. M. El Mhamdi, R. Guerraoui, and J. Stainer, "Machine learning with adversaries: Byzantine tolerant gradient descent," in *Advances in Neural Information Processing Systems*, vol.30, 2017.
- [2] D. Yin, Y. Chen, R. Kannan, and P. Bartlett, "Byzantine-robust distributed learning: Towards optimal statistical rates," in *International Conference on Machine Learning*, pp.5650–5659, PMLR, 2018.
- [3] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, "Communication-efficient learning of deep networks from decentralized data," in *Artificial intelligence and statistics*, pp.1273–1282, PMLR, 2017.
- [4] T. Li, A. K. Sahu, M. Zaheer, M. Sanjabi, A. Talwalkar, and V. Smith, "Federated optimization in heterogeneous networks," in *Proceedings of Machine Learning and Systems*, vol.2, pp.429–450, 2020.
- [5] S. P. Karimireddy, S. Kale, M. Mohri, S. Reddi, S. Stich, and A. T. Suresh, "Scaffold: Stochastic controlled averaging for federated learning," in *International Conference on Machine Learning*, pp.5132–5143, PMLR, 2020.
- [6] Q. Li, B. He, and D. Song, "Model-contrastive federated learning," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp.10713–10722, 2021.
- [7] C. Xie, S. Koyejo, and I. Gupta, "Asynchronous federated optimization," in *12th Annual Workshop on Optimization for Machine Learning*, 2019.
- [8] E. M. El Mhamdi, R. Guerraoui, and S. Rouault, "The hidden vulnerability of distributed learning in byzantium," in *International Conference on Machine Learning*, pp.3521–3530, PMLR, 2018.
- [9] X. Cao, M. Fang, J. Liu, and N. Z. Gong, "Fltrust: Byzantine-robust federated learning via trust bootstrapping," in *Network and Distributed System Security Symposium*, 2020.
- [10] T. Lin, L. Kong, S. U. Stich, and M. Jaggi, "Ensemble distillation for robust model fusion in federated learning," in *Advances in Neural Information Processing Systems*, vol.33, pp.2351–2363, 2020.
- [11] H.-Y. Chen and W.-L. Chao, "Fedbe: Making bayesian model ensemble applicable to federated learning," in *International Conference on Learning Representations*, 2021.
- [12] J. Wang, Q. Liu, H. Liang, G. Joshi, and H. V. Poor, "Tackling the objective inconsistency problem in heterogeneous federated optimization," in *Advances in Neural Information Processing Systems*, vol.33, pp.7611–7623, 2020.
- [13] A. Reiszadeh, A. Mokhtari, H. Hassani, A. Jadbabaie, and R. Pedarsani, "Fedpaq: A communication-efficient federated learning method with periodic averaging and quantization," in *International Conference on Artificial Intelligence and Statistics*, pp.2021–2031, PMLR, 2020.
- [14] Y. Lin, S. Han, H. Mao, Y. Wang, and W. J. Dally, "Deep gradient compression: Reducing the communication bandwidth for distributed training," *arXiv preprint arXiv:1712.01887*, 2017.
- [15] F. Lai, X. Zhu, H. V. Madhyastha, and M. Chowdhury, "Oort: Efficient federated learning via guided participant selection," in *15th USENIX Symposium on Operating Systems Design and Implementation*, pp.19–35, 2021.
- [16] E. Bagdasaryan, A. Veit, Y. Hua, D. Estrin, and V. Shmatikov, "How to backdoor federated learning," in *International Conference on Artificial Intelligence and Statistics*, pp.2938–2948, PMLR, 2020.

واژه‌نامه انگلیسی به فارسی

B

Byzantine بیزانتین

S

Straggler گره‌کُند